

clevrer: 碰撞事件 视频呈现与推理

凯欣怡*
哈佛大学

创甘*
MIT-IBM Watson人工智能实验室

李云珠
MIT CSAIL

普什蒂姆·科利
DeepMind

吴佳军
MIT CSAIL

安东尼奥·托拉尔巴
MIT CSAIL

约书亚·B·特南鲍姆
MIT BCS, CBMM, CSAIL

摘要

从视频中推断时间顺序与因果关系的能力是人类智能的核心所在。然而，大多数视频推理基准测试主要关注从复杂的视觉和语言输入中提取模式，而非因果结构。我们研究了互补性问题，旨在探索具有简单视觉特征的物体视频背后的时间与因果结构。为此，我们推出了“视频推理中的碰撞事件”（Clevation）数据集——这是一个用于系统评估各类推理任务计算模型的诊断性视频数据集。该数据集基于人类因果判断理论设计，包含四类问题：描述性问题（如“是什么颜色”）、解释性问题（“是什么导致了……”）、预测性问题（“接下来会发生什么”）以及反事实性问题（“如果……会怎样”）。我们基于该基准测试评估了多种最先进的视觉推理模型。虽然这些模型在基于感知的任务（描述性任务）中表现优异，但在因果任务（解释性、预测性和反事实性任务）中表现较差，这表明一套原则性的因果推理方法应当具备同时处理复杂视觉与语言输入、并理解其潜在动态及因果关系的能力。

我们还研究了一种预言模型，该模型通过符号表示明确地整合了这些组件。

1 引言

从视频中识别物体并推理其在物理事件中的行为，是人类认知发展的核心（Spelke, 2000）。人类——即便是年幼的婴儿——也能根据运动将物体片段归类，并运用物体恒存性、实体性和连续性等概念来解释已发生事件、推断即将发生的事件，以及想象反事实情境下的可能结果。复杂视觉推理问题已在人工智能和计算机视觉领域得到广泛研究，这得益于各类静态图像数据集（Antol 等人，2015；Zhu 等人，2016；Hudson & Manning, 2019）和视频数据集（Jang 等人，2017；Tapaswi 等人，2016；Zadeh 等人，2019）的引入。然而，尽管这些数据涵盖了复杂多样的视觉场景，推理过程背后的底层逻辑、时间与因果结构却鲜有深入探讨。

在本文中，我们从一个互补的角度研究视频中的时序与因果推理问题：受近期视觉推理数据集 CLEVR（Johnson 等人，2017a）的启发，我们简化了视觉识别问题，但着重强调了相互作用对象背后复杂的时序与因果结构。我们为此问题引入了一个视频推理基准，其灵感来源于发展心理学（Gerstenberg 等人，2015；Ullman, 2015）。同时，我们还在该基准上评估了当前各种视觉推理模型的性能与局限性。

我们的基准测试工具名为“视频表示与推理中的碰撞事件”（Clevrer），这是一个用于在完全受控环境中进行时序与因果推理的诊断性视频数据集。Clevrer的设计遵循两条原则：首先，所发布的任务应专注于时序与因果领域的逻辑推理，同时保持简洁性，并尽量减少对视觉场景和语言的偏见；其次，该数据集必须完全受控且标注详尽，以确保其能够有效支持相关研究。

*表示贡献相等。项目页面：<http://clevrer.csail.mit.edu/>




图1：来自我们“视频呈现与推理碰撞实验”（Clevrer）数据集的示例视频、问题及答案。Clevrer旨在评估计算模型能否理解视频内容（I，描述性问题）、解释事件成因（II，解释性问题）、预测未来事件（III，预测性问题）以及构想反事实场景（IV，反事实问题）。在四幅图像（a-d）中，仅为可视化目的，我们采用了频闪成像技术来呈现物体运动。图注（例如“第一次碰撞”）旨在帮助读者更好地理解画面内容，并非数据集的组成部分。

CLEVRer能够处理复杂的推理任务，并为模型在这些任务上的表现提供有效的诊断工具。该数据集包含20,000段物体碰撞的合成视频以及超过300,000个问答样本（图1）。我们重点关注视频中复杂逻辑推理的四个关键要素：描述性问题（例如“是什么颜色”）、解释性问题（“是什么导致了这一现象”）、预测性问题（“接下来会发生什么”）以及反事实性问题（“如果……会怎样”）。CLEVRer还提供了视频中每个物体的真实运动轨迹和事件历史记录。每个问题都配有对应其底层逻辑的功能程序。如表1所示，CLEVRer在多个维度上完善了现有的视觉推理基准测试，并引入了若干创新性任务。

我们还对Clever平台上多种最先进的视觉推理模型进行了分析。尽管这些模型在描述性问题上表现优异，但它们缺乏因果推理能力，在解释性、预测性及反事实性问题上表现欠佳。因此，我们确定了完成该任务所需的三个关键要素：识别视频中的物体与事件；建模物体与事件间的动态关系及因果联系；以及理解问题背后的符号逻辑。作为对该原则的初步探索，我们研究了一种名为神经符号动态推理（NS-DR）的预言模型——该模型通过符号化视频表征明确整合了上述各组件，并对其性能与局限性进行了评估。

2 相关工作

我们的研究可在以下三个近期研究方向中占据独特地位：视频理解、视觉问答以及物理与因果推理。

视频理解。随着大规模视频数据集的出现（Caba Heilbron等人，2015；Kay等人，2017），联合视频与语言理解任务备受关注。这包括视频字幕生成（Guadarrama等人，2013；Venugopalan等人，2015；Gan等人，2017）、基于自然语言查询的视频片段定位（Gao等人，2017；Hendricks等人，2017）以及视频问答。特别是，近期研究探索了多种方法，以获取视频数据并将其作为各类推理任务的基础。其中，MovieQA（Tapaswi等人，2016）、TGIF-QA（Jang等人，2017）和TVQA（Lei等人，2018）均基于真实视频和人工生成的问题；Social-IQ（Zadeh等人，2019）则基于真实视频探讨人类社会互动中的因果关系。COG（Yang等人，2018）和MarioQA（Mun等人，2017）采用模拟环境生成合成数据及可控推理任务。相比之下，clever专注于基于对象动态与物理交互的因果关系，并涵盖描述、解释、预测及反事实推理等多种任务类型；同时该方法还强调视觉与逻辑语境中的组合性。

视觉问答：视觉问答领域已提出多项基准任务。Visual Question Answering（VQA）数据集（Antol等人，2015）基于大规模云端真实图像与人工生成的问题，为自上而下的视觉推理奠定了重要基础；而CLEVR数据集（Johnson等人，2017a）则采用自下而上的方法，通过受控的封闭域合成图像与问题框架来定义任务，这些任务具备组合属性及逻辑轨迹。最近，GQA数据集（Hudson & Manning，2019）将合成的组合式问题应用于真实图像。VCR数据集（Zellers

数据集	视频	诊断性的 注释	时间性的：与时间相关的 关系	解释；说明	预测	反事实的
VQA (Antol 等人, 2015)	×	×	×	×	×	×
CLEVR (Johnson 等人, 2017a)	×	✓	×	×	×	×
COG (Yang 等人, 2018)	×	✓	✓	×	×	×
VCR (Zellers 等人, 2019)	×	✓	×	✓	×	✓
GQA (Johnson 等人, 2017a)	×	✓	×	×	×	×
TGIF-QA (Jang 等人, 2017)	✓	×	✓	×	×	×
MovieQA (Tapaswi 等人, 2016)	✓	×	✓	✓	×	×
MarioQA (Mun 等人, 2017)	✓	×	✓	✓	×	×
TVQA (Lei 等人, 2018)	✓	×	×	✓	×	×
社交智商 (Zadeh 等人, 2019)	✓	×	×	✓	×	×
Cleverer (我们的)	✓	✓	✓	✓	✓	✓

表1: Cleverer与其他图像和视频视觉推理基准方法的比较。Cleverer是一个在受控环境下创建的、标注完善的视频推理数据集，涵盖了描述、解释、预测及反事实推理等多种推理任务。

等人 (2019) 探讨了基于常识的解释与假设判断方法。此外，已有众多视觉推理模型被提出 (Hudson & Manning, 2018; Santoro 等人, 2017; Hu 等人, 2017; Perez 等人, 2018; Zhu 等人, 2017; Mascharka 等人, 2018; Suarez 等人, 2018; Cao 等人, 2018; Bisk 等人, 2018; Misra 等人, 2018; Aditya 等人, 2018)。本文简要综述其中几种模型：堆叠注意力网络 (SAN) (Yang 等人, 2016) 为端到端视觉问答模型引入了分层注意力机制；MAC网络 (Hudson & Manning, 2018) 将视觉与语言注意力相结合用于组合式视觉推理；IEP模型 (Johnson 等人, 2017b) 提出通过神经程序执行来解答问题。NS-VQA 模型 (Yi 等人, 2018) 通过将图像的基于对象的抽象表示与符号程序执行相结合，实现了感知与逻辑推理的分离。本研究探讨了因果推理这一互补性问题，并评估了这些基线方法的优势与局限性。

物理与因果推理。我们的工作也与关于学习场景动态以进行物理和因果推理的研究相关 (Lerer 等人, 2016; Battaglia 等人, 2013; Mottaghi 等人, 2016; Fragkiadaki 等人, 2016; Battaglia 等人, 2016; Chang 等人, 2017; Agrawal 等人, 2016; Finn 等人, 2016; Shao 等人, 2014; Fire 与 Zhu, 2016; Pearl, 2009; Ye 等人, 2018)，无论是直接从图像中提取 (Finn 等人, 2016; Ebert 等人, 2017; Watters 等人, 2017; Lerer 等人, 2016; Mottaghi 等人, 2016; Fragkiadaki 等人, 2016)，或基于环境的符号化、抽象化表征 (Battaglia 等人, 2016; Chang 等人, 2017)。与我们的研究同步，CoPhy (Baradel 等人, 2020) 在反未来场景中研究物理动力学预测；cater (Girdhar & Ramanan, 2020) 提出了一个用于组合动作时间推理的合成视频数据集；而cleverer通过将动力学建模与组合因果推理相结合，并将推理任务扎根于语言领域，对这些研究进行了补充。

3 CLEVRER 数据集

Cleverer数据集专注于视频中的时序推理与因果推理研究。该数据集在完全受控的合成环境中精心设计，能够支持复杂的推理任务，为模型提供有效的诊断工具，同时简化视频识别与语言理解过程。视频内容展示了由物理引擎模拟的平坦桌面表面物体的运动与碰撞场景（如图1所示），并附有所有物体及事件的真实运动轨迹与历史记录。每个视频均包含机器生成的四类问题：描述性问题（“是什么颜色”、“有多少个”）、解释性问题（“是什么导致了……”）、预测性问题（“接下来会发生什么”）以及反事实性问题（“如果……会怎样”）。每道问题均对应一个功能程序。

3.1 视频

Cleverer数据集包含 10,000 条用于训练的视频、5,000 条用于验证的视频以及 5,000 条用于测试的视频。所有视频时长均为 5 秒。这些视频由物理引擎生成（该引擎模拟物体运动），并由图形引擎负责渲染帧画面。数据集中的更多示例可参见补充材料C。

对象与事件。Cleverer 视频中的对象采用了与 CLEVR (Johnson 等人, 2017a) 相似的组合内在属性，包括三种形状（立方体、球体和圆柱体）、两种材质（金属和橡胶）以及八种颜色（灰色、红色、蓝色、绿色、棕色、青色、紫色等）。




图2: 来自 *cleverer* 的示例问题与程序。左侧: 描述性问题。中间与右侧: 多选题-选择题。每个选项均可与问题配对形成联合逻辑轨迹(黄色)。所有对象尺寸相同, 因此碰撞时不会发生垂直弹跳。在每个视频中, 我们禁止对象重复出现, 使得三个属性的每种组合都能唯一标识一个对象。在此约束下, 每个对象的所有内在属性均被随机采样。我们进一步引入三种事件类型: **进入**、**退出**和**碰撞**, 每种事件包含固定数量的对象参与者: 碰撞事件涉及2个对象, 进入和退出事件各涉及1个对象。这些对象与事件共同构成了视频的抽象表征。这些真实标注数据结合对象运动轨迹, 使得模型诊断成为可能——这正是完全受控环境提供的核心优势之一。

因果结构。 *Cleverer* 视频中的对象与事件展现出丰富的因果关系结构: 当某个事件是对象参与的第一个事件时, 该事件可由该对象引发; 若某个因果事件紧接在同一对象上发生的后续结果事件之前, 则该事件也可由该对象引发。例如, 若一个球体先与立方体碰撞, 随后又与圆柱体碰撞, 则第一次碰撞与立方体共同“引发”了第二次碰撞。具有复杂因果结构的对象运动轨迹通过以下递归过程生成: 首先随机初始化一个运动对象, 随后添加另一个初始位置和速度设置为会与第一个对象发生碰撞的对象; 接着重复此过程向场景中添加更多对象和碰撞事件。所有碰撞对与运动轨迹均通过随机方式生成。我们剔除了同一物体对之间发生多次碰撞的模拟结果。

视频生成。 *cleverer* 视频基于模拟运动轨迹生成, 包含每个物体在每个时间步的位置和姿态。我们采用 *Bullet* (Coumans, 2010) 物理引擎进行运动模拟, 每段模拟时长为七秒。首先将运动轨迹进行降采样以适应输出视频的帧率(每秒25帧), 随后将前五秒的运动数据输入 *Blender* (Blender Online Community, 2016) 渲染出逼真的物体运动与碰撞视频帧, 剩余两秒数据则保留用于预测任务。需要特别说明的是, *cleverer* 在渲染时采用了与 *CLEVR* 相同的软件及参数设置。

3.2 问题

我们将每个视频与机器生成的问题配对, 这些问题用于描述性、解释性、预测性及反事实推理。四种类型的问题示例见图1。每个问题都对应一个可在视频动态场景中执行的功能程序。与 *CLEVR* (Johnson 等人, 2017a) 不同, 我们的问题侧重于视频中物体和事件的时间与因果关系特征。我们排除了所有关于静态物体属性的问题——这类问题可通过查看视频画面直接解答。

单帧数据集 *Cleverer* 包含219,918个描述性问题、33,811个解释性问题、14,298个预测性问题以及37,253个反事实性问题。问题的具体分布与分类详见图3及补充材料A。

描述性问题。 描述性问题用于评估模型理解并推理视频动态内容及时间关系的能力。这些推理任务基于对象与事件属性的组合空间, 涵盖内在属性(颜色、材质、形状)、运动、碰撞以及时间顺序等要素。所有描述性问题均为“开放式”, 可由单个词语作答。描述性问题包含多种子类型, 包括**计数**、**存在**、**查询颜色**、**查询材质**和**查询形状**。各子类型的分布情况如图3所示。我们对每个子类型内的答案进行均匀采样, 以减少答案偏差。

解释性。 解释性问题通过询问某个对象或事件是否导致了另一个事件, 来探究视频的因果结构。若 A 是事件 B 的原因, 则称事件 A 导致事件 B 。




图3: 各类问题类型的分布。

左图: 四种主要问题类型的分布情况; 右图: 描述性子类型的分布情况。

B 在因果图中的祖先。类似地，如果对象 O 参与了 A 或任何其他导致 A 的事件，则对象 O 即是事件 A 的原因。解释性问题为最多包含四个选项的多项选择题，每个选项代表视频中的某个事件或对象。模型需要选择所有与问题描述匹配的选项。每个问题可能有多个正确选项。我们通过采样选项来平衡正确与错误选项的数量，并最小化纯文本偏差。**预测性**。预测性问题测试模型在视频结束后预测未来事件可能发生的能力。与解释性问题类似，预测性问题也是多项选择题，其选项代表可能发生或不会发生的候选事件。由于视频结束后发生的事件较为稀疏，我们为每个预测性问题提供两个选项以减少偏差。**反事实**。反事实问题探究在特定假设条件下（例如移除某个对象）视频的最终结果。模型需要选择在指定条件下可能发生或不会发生的事件。每个问题最多有四个选项，正确与错误选项的数量保持均衡。无论是预测性问题还是反事实性问题，都需要掌握视频背后物体动态机制的知识，并具备对未观测事件进行想象和推理的能力。

程序表示。在cleaver系统中，每个问题都由一个树状结构的功能程序表示，如图2所示。程序首先接收来自视频的对象或事件列表，随后该列表会经过一系列过滤模块处理——这些模块会筛选列表中的条目并将它们连接到树状分支中，从而输出一组目标对象和事件。最后调用输出模块来查询目标输出的指定属性。对于多项选择题，每个问题及其选项对应独立的程序，这些程序可协同执行以生成表示选择是否正确的“是/否”标记。所有程序模块列表详见补充材料B。

问题生成。CLEVER中的问题通过多步骤流程生成。针对每种问题类型，系统会选取预定义的逻辑模板。该逻辑模板可进一步填充与视频上下文相关的属性（例如用于识别待查询对象的颜色、材质、形状），随后转换为自然语言。我们首先为每个视频生成所有可能问题的详尽列表。为避免语言偏见，我们会从该列表中随机抽取样本，以确保各类问题的答案分布均衡，并最大限度降低整个数据集中问题与答案之间的相关性。

4 基线评估

在本节中，我们评估并分析了多种基线模型在Clevrer数据集上的视频推理性能。对于描述性问题，这些模型将每个问题视为针对所有可能答案的多分类任务；对于选择题问题，每个问题-选项组合则被视为二分类任务，用于判断所选答案是否正确。

4.1 模型详情

我们评估的基础模型可分为三大类：纯语言模型、视频问答模型以及组合式视觉推理模型。

纯语言模型。该模型家族包含一些弱基线模型，它们仅依赖问题输入来评估CLEVERR中的语言偏见。**Q型（随机）**从答案空间中均匀采样答案，或对多项选择题随机选取每个选项。

Q型（高频）为每种题型选择训练集中出现频率最高的答案。**LSTM**使用基于Google新闻语料库（Mikolov 等人，2013）预训练的词嵌入来编码输入问题，并通过 LSTM（Hochreiter & Schmidhuber, 1997）处理该序列。随后对最终隐藏状态应用 MLP 来预测答案的分布。

视频问答。我们还评估了以下同时依赖视频和语言输入的模型：**CNN+ MLP**通过卷积神经网络（CNN）从输入视频中提取特征，并利用预训练词嵌入的平均值对问题进行编码（Mikolov等，2013）。随后将视频与语言特征联合输入 MLP 进行答案预测；**CNN+ LSTM**采用相同的视频特征提取架构，但使用 LSTM 的最终状态进行答案预测；**TVQA**（Lei 等，2018）提出了一种多流端到端神经模型，该模型为视频问答设定了当前最先进标准。我们采用了通过视频帧解析器获取的属性感知型对象中心特征（**TVQA+**），同时纳入了近期结合异构记忆与多模态注意力机制的模型（**Memory**）（Fan 等，2019），该模型在多个数据集上均展现出卓越性能。

方法	描述性的	解释性的		预测性的		反事实的	
		根据个人选择.	关于问题.....	根据个人选择.	关于问题.....	根据个人选择.	关于问题.....
Q型 (随机)	29.2	50.1	8.1	50.7	25.5	50.1	10.3
Q型 (常见)	33.0	50.2	16.5	50.0	0.0	50.2	1.0
激光扫描跟踪法	34.7	59.7	13.6	50.6	23.2	53.8	3.1
CNN+MLP	48.4	54.9	18.3	50.5	13.2	55.2	9.0
CNN+LSTM	51.8	62.0	17.5	57.9	31.6	61.2	14.7
TVQA+	72.0	63.3	23.7	70.3	48.9	53.9	4.1
记忆力	54.7	53.7	13.9	50.0	33.1	54.2	7.0
IEP (V)	52.8	52.6	14.5	50.0	9.7	53.4	3.8
TbD-net (V)	79.5	61.6	3.8	50.3	6.5	56.1	4.4
MAC (V)	85.6	59.5	12.5	51.0	16.5	54.6	13.7
MAC (V+)	86.4	70.5	22.3	59.7	42.9	63.5	25.1

表2: 基于Clever的视觉推理基线模型问答准确率。所有模型均在完整训练集上进行训练。IEP(V)模型和TbD-net(V)模型使用1000个程序来训练程序生成器。

组合式视觉推理。CLEVR 数据集 (Johnson 等人, 2017a) 开创了组合式视觉推理的新方向, 该方法强调逻辑与视觉上下文中的复杂性及组合性。我们对多个表现最佳的模型进行了改进, 并将其应用于我们的视频基准测试。IEP模型 (Johnson 等人, 2017b) 采用神经程序执行技术进行图像视觉推理; 我们在基于程序的视频推理任务 (**IEP (V)**) 中采用了相同方法: 用clever提供的程序原语替换原有代码, 并将执行模块应用于卷积 LSTM (Shi 等人, 2015) 提取的视频特征上。TbD-net (Mascharka 等人, 2018) 采用类似策略, 将输入问题解析为程序代码, 随后构建一个作用于图像特征注意力图的神经网络, 最终将注意力聚焦后的图像特征送入输出层进行分类。我们采用相同的方法, 在视频特征空间上应用时空注意力机制 (**TbD-net (V)**)。MAC模型 (Hudson & Manning, 2018) 在图像特征图和问题上均采用了联合注意力机制, 从而在无需程序监督的情况下实现了优异的 CLEVR 性能。我们通过在视频帧间添加时间注意力单元来改进模型, 生成视频的潜在编码 (**MAC (V)**), 随后将该视频特征输入MAC网络以输出答案分布。我们还研究了一种增强方法: 通过叠加所有帧中物体的分割掩码, 并根据其内在属性值进行标注, 构建了具备对象感知能力的视频特征 (**MAC (V+)**)。

实现细节。我们采用预训练的 ResNet-50 (He 等人, 2016) 从视频帧中提取特征。对于基于 CNN 的方法, 我们使用 2,048 维的 pool5 层输出; 而对于 MAC、IEP 和 TbD-net, 则使用 14×14 的特征图。IEP 和 TbD-net 的程序生成器是在 1000 个程序上训练的。我们均匀采样每个视频的 25 帧作为输入。对象分割掩码和属性由一个包含对象检测器和属性网络的视频解析器生成。

4.2 结果

我们在表2中总结了所有基线模型的性能表现。这些模型在广泛的任务范围内展现出不同的性能, 表明clever能够有效评估模型在不同领域的优势与局限性。所有模型均在训练集上训练至收敛, 随后在验证集上进行调参, 并在测试集上进行评估。

评估指标。对于描述性问题, 我们通过将预测的答案标记与真实答案进行比较来计算准确率。对于选择题, 我们采用两项指标: 选项准确率衡量模型在所有问题中对单个选项的整体正确性; 问题准确率衡量整个问题的正确性, 要求所有选项均被正确选择。

描述性推理。描述性问题会从多个角度查询视频内容。要在此类问题中取得良好表现, 模型不仅需要准确识别视频中的物体和事件, 还需理解问题背后的构成逻辑模式。换言之, 描述性问题要求模型对视觉和语言信号进行强大的感知与逻辑运算。如表2所示, 仅依赖问题输入的 LSTM 基线模型在描述性问题上的表现较差, 仅优于随机基线模型。




图4: 我们的模型包含四个组件: 视频帧解析器, 用于生成视频帧的基于对象的表示; 问题解析器, 将问题转换为函数式程序; 动态预测器, 用于提取并预测视频中的动态场景; 以及符号程序执行器, 负责在动态场景上运行该程序以获取答案。

优势微乎其微。这表明Clevrer在处理这些问题时偏差极小。视频问答模型（包括最先进的TVQA +模型Lei 等人, 2018）表现更优。但由于这些模型在处理问题逻辑中的组合性特征及视觉上下文方面能力有限, 仍难以在该任务中取得优异表现。相比之下, 专为组合推理设计的模型——如基于神经程序执行的TbD-net和引入联合注意力机制的MAC——能够取得更具竞争力的性能表现。

因果推理。关于描述性问题的实验结果证明了将视觉与语言感知能力结合组合逻辑运算的模型所具有的强大性能。然而, 因果推理任务（解释性、预测性、反事实性）需要超越单纯感知层面的深入理解。我们的评估结果（表2）显示, 大多数基线模型在这些问题上的表现较差。在描述性问题上表现优异的组合推理模型（MAC(V)和TbD-net(V)）在因果任务上仅比随机基线和纯语言基线有微小提升。不过, 我们注意到采用对象感知表示的模型性能有所改善: TVQA +在预测性问题上达到高准确率, 而MAC(V+)在所有任务上的表现均优于MAC(V)。

根据我们的评估结果, 我们总结出以下关键发现: 首先, 以对象为中心的表征对于因果推理任务至关重要。这一点得到了以下证据的支持: 在使用能反映对象实例及其属性的特征后, MAC(V+)相比MAC(V)取得了显著提升; 同时, TVQA +在预测性问题上的表现也非常出色。其次, 所有基线模型均缺乏明确建模对象动态行为及碰撞事件间因果关系的组件。因此, 这些模型在处理涉及未观测场景的任务时表现欠佳, 尤其在反事实任务中表现尤为糟糕。由此可见, 将对象中心化表征与动态建模相结合, 为解决因果推理任务提供了极具前景的研究方向。

5 神经符号动态推理

对Clevrer的基线评估揭示了因果推理所需的两个关键要素: 一种以对象为中心的视频表征, 能够感知对象与事件之间的时序及因果关系; 以及一个能够在未观测或反事实场景下预测对象动态变化的动力学模型。然而, 将这些要素与视频及语言理解相结合面临以下挑战: 首先, 所有独立的模型组件都应基于相同的视频、问题、动态及因果关系表征进行运作; 其次, 该表征需能识别对象与事件之间的组合关系。我们借鉴Yi 等人(2018)的研究思路, 构建了一个基于符号化表征的预言模型, 将视频感知、语言理解与动态建模相整合。我们的神经符号动态推理(NS-DR)模型融合了用于模式识别和动态预测的神经网络, 以及用于因果推理的符号逻辑。如图4所示, NS-DR由视频帧解析器(图4-I)、神经动态预测器(图4-II)、问题解析器(图4-III)和程序执行器(图4-IV)组成。我们将在下文及补充材料B中详细说明该模型的各个组件。

视频帧解析器。该视频帧解析器作为感知模块，独立于模型的其他组件运作，可生成以对象为中心的视频帧表示。该解析器采用Mask R-CNN (He 等人, 2017)，可在每个视频帧上执行目标检测和场景解渲染 (Wu 等人, 2017)。我们使用ResNet-50 FPN (Lin 等人, 2017; He 等人, 2016) 作为骨干网络。对于每个输入视频帧，网络会输出目标掩码提案、对应于内在属性（颜色、材质、形状）的标签，以及表示提案置信度的分数（具体细节参见He等人He 等人, 2017）。该视频解析器基于从训练集随机抽取的4000帧视频帧进行训练，这些视频帧均包含目标掩码和属性标注。

神经动力学预测器。我们采用传播网络 (PropNet) (Li 等人, 2019) 进行动力学建模。该模型是一种可学习的物理引擎，基于交互网络 (Battaglia 等人, 2016) 开发，能够在动态场景中对对象和关系进行更新。模型接收来自视频解析器的对象提议，并学习对象在各帧间的动力学行为以预测运动轨迹和碰撞事件。PropNet将动力系统表示为有向图 $G = \langle O, R \rangle$ ，其中顶点 $O = \{o_i\}$ 代表对象，边 $R = \{r_k\}$ 代表关系。每个对象（顶点） o_i 和关系（边） r_k 可进一步表示为： $o_i = \langle s_i, aoi \rangle$ ； $r_k = \langle u_k, v_k, ark \rangle$ ，其中 s_i 表示对象 i 的状态； aoi 表示其内在属性； u_k, v_k 是表示通过边 r_k 连接的接收方与发送方顶点索引的整数； ark 表示边 r_k 的状态，用于指示两个对象之间是否存在碰撞。在本案例中， s_i 是通过对小历史窗口内的元组 $\langle c_i, m_i, p_i \rangle$ 进行拼接来编码运动历史，其中 c_i 和 m_i 分别是裁剪自 p_i 的对应图像块与掩码块—— p_i 对应原始图像中掩码的x-y位置（示例参见图4中的青色金属立方体）。PropNet通过多步消息传递机制处理效应的瞬时传播。更多详情请参阅补充材料B。

问题解析器。我们采用基于注意力机制的seq2seq模型 (Bahdanau 等人, 2015) 将输入问题解析为其对应的功能程序。该模型由双向 LSTM 编码器和带有注意力机制的 LSTM 解码器组成，与 (Yi 等人, 2018) 中的问题解析器类似。对于选择题，我们分别使用两个网络对问题和选项进行解析。给定输入词序列 $(x_1, x_2, \dots, x_I)$ ，编码器首先在每一步生成双向潜在编码：

$$efi, hfi = \text{LSTM}(\Phi_I(x_i), hfi_{-1}), \quad (1)$$

$$ebi, hbi = \text{LSTM}(\Phi_I(x_i), hbi_{+1}), \quad (2)$$

$$e_i = [e_i^f, e_i^b]. \quad (3)$$

随后，解码器利用注意力机制，从潜在编码中生成一系列程序标记 $(y_1, y_2, \dots, y_J)$ ：

$$v_j = \text{LSTM}(\Phi_O(y_{j-1})), \quad (4)$$

$$\alpha_{ji} \propto \exp(v_j^T e_i), \quad c_j = \sum_i \alpha_{ji} e_i, \quad (5)$$

$$y_j^* \sim \text{softmax}(W \cdot [q_j, c_j]). \quad (6)$$

在训练阶段，输入的程序标记 $\{y_j\}$ 用于在每一步 $j=1, 2, 3, \dots, J$ 中生成预测标签 $y_{j-1} \rightarrow y_j^*$ 。生成的标签 y_j^* 随后与 y_j 进行比较，以计算训练损失。在测试阶段，解码器通过将前一步的采样预测作为当前步骤 $y_j^* = y_j$ 的输入来执行序列输出。输出过程会在出现结束标记或序列达到特定最大长度时终止。对于编码器和解码器 LSTM，我们采用相同的参数配置：两个包含256个单元的隐藏层，以及一个300维的词嵌入向量。**程序执行器。**该程序执行器会显式地在动力学预测器提取的动作和事件轨迹上执行程序，并输出问题的答案。它由一组用Python实现的功能模块组成。给定一个输入程序后，执行器首先会组装各个模块，随后遍历程序树结构。最终模块的输出即为目标问题的答案。程序模块主要分为三类：输入模块、过滤模块和输出模块。输入模块是程序树的入口点，可以直接调用动态预测器的输出结果。例如，在描述性问题的程序中常见的“事件”和“对象”模块，其作用就是输入视频中观察到的所有事件和对象。过滤模块则会对输入的对象/事件执行逻辑运算。

方法	描述性的	解释性的		预测性的		反事实的	
		根据个人选择。	关于问题.....	根据个人选择。	关于问题.....	根据个人选择。	关于问题.....
NS-DR	88.1	87.6	79.6	82.9	68.7	74.1	42.2
NS-DR (NE)	85.8	85.9	74.3	75.4	54.1	76.1	42.0

表3: NS-DR在cleverer数据集上的定量结果。我们在所有四种问题类型上评估了该模型，并研究了模型的一个变体——NS-DR (NE)，该变体仅包含“无事件”条件下的动态预测器生成的运动轨迹数据。我们的问题解析器经过1000个程序训练而成。

基于指定的内在属性、运动状态、时间顺序或因果关系，输出模块会返回答案标签。对于开放式描述性问题，执行器会从答案空间返回一个标记；对于选择题，执行器首先运行选择程序，然后将结果发送给问题程序以输出“是/否”标记。NS-DR程序执行器中所有模块的完整列表详见补充材料B。结果：我们在表3中总结了NS-DR在CLEVERER数据集上的性能。在描述性问题上，当问题解析器经过1,000个程序训练后，我们的模型准确率达到88.1%，优于其他基线方法；在解释性、预测性和反事实性问题上，模型性能提升更为显著。我们还研究了模型的变体NS-DR (No Events/NE)，该版本仅使用动态预测器生成预测性和反事实性运动轨迹，并通过碰撞物体的速度变化来识别碰撞事件。NS-DR (NE)的表现与完整模型相当，这表明我们的解耦系统能够适应动态建模的其他方法。我们还对训练问题解析器所需的程序数量进行了消融实验。如图5所示，NS-DR在使用1,000个程序时，对所有问题类型均能发挥出全部功能。

我们重点强调该模型的以下贡献：首先，NS-DR在视觉推理任务中融入了动态规划机制，这直接实现了对未观测运动和事件的预测能力，使模型能够胜任预测性和反事实性任务。这表明动态规划在基于语言的视觉推理任务中具有巨大潜力，而NS-DR正是朝着这一方向迈出的初步探索。其次，符号表示为视觉、语言、动态关系及因果关系提供了强大的共同基础。通过设计，该机制使模型能够明确捕捉视频因果结构及问题逻辑背后的组合性特征。

我们进一步讨论了NS-DR的局限性，并提出了未来研究的可能方向。首先，视频与问题解析器的训练依赖于额外的监督数据，例如对象掩码、属性和问题程序。尽管与端到端方法（即数千帧标注画面及程序）相比，训练所需的数据量极小，但在实际应用中这些数据难以获取。这一限制可通过采用无监督/弱监督方法进行场景分解和概念发现来缓解（Burgess 等人，2019；Mao 等人，

2019）。其次，在需要长期动态预测的任务上（如

反事实问题。这表明我们需要一个更优的动力学模型，能够生成更稳定、更精确的轨迹。

Cleverer为评估此类动力学模型的预测能力提供了基准。

6 结论

我们对视频中的时序与因果推理进行了系统性研究。这一深刻而具有挑战性的问题深深植根于人类智能的基础原理，目前才开始借助“现代”人工智能工具进行探索。我们提出了一系列基准任务，以更好地推动该领域的研究进展。同时，我们认为视频理解与推理不应仅限于被动的知识提取，而应致力于构建对视频动态特征及因果关系的内在认知。




图5: 本模型在使用不同数量程序训练问题解析器时的性能表现。

这对于复杂因果条件下的动态机器人操控等实际应用至关重要。我们新推出的clever数据集和NS-DR模型正是朝这一方向迈出的初步步伐。我们希望，随着图网络、视觉预测模型和神经符号算法的最新进展，深度学习社区未来能够在更贴近现实的场景中重新审视这一经典问题，从而捕捉到超越模式识别的真正智能。

致谢。我们感谢毛佳远提供的宝贵讨论与建议。本研究部分由美国海军研究办公室（ONR）MURI 项目（编号：N00014-16-1-2007）、脑、心智与机器研究中心（CBMM，由美国国家科学基金会STC奖项CCF-1231216资助）以及IBM研究院共同资助。

参考文献

Somak Aditya, Yezhou Yang 和 Chitta Baral。面向视觉问答的端到端神经架构的显式推理。收录于 *AAAI*, 2018。3

普尔基特·阿格拉瓦尔、阿什文·奈尔、彼得·阿贝尔、吉滕德拉·马利克和谢尔盖·莱文。《通过戳刺学习：对直观物理的体验式学习》。 *NeurIPS*, 2016。3

斯坦尼斯瓦夫·安托尔、艾什瓦里娅·阿格拉瓦尔、卢佳森、玛格丽特·米切尔、德鲁夫·巴特拉、C·劳伦斯·齐特尼克和德维·帕里克。VQA：视觉问答。收录于 *ICCV*, 2015。1、2、3

德米特里·巴赫达瑙、赵京贤与约书亚·本吉奥。《通过联合学习对齐与翻译实现神经机器翻译》。 *ICLR*, 2015。8

法比安·巴拉德尔、娜塔莉亚·内韦罗娃、朱利安·米勒、格雷格·莫里与克里斯蒂安·沃尔夫。Cophy：物理动力学的反事实学习。载于 *ICLR*, 2020。3

彼得·W·巴塔利亚、杰西卡·B·哈姆里克与约书亚·B·特南鲍姆。《模拟作为物理场景理解的引擎》。 *PNAS*, 110(45):18327–18332, 2013。3

Peter W. Battaglia, Razvan Pascanu, Matthew Lai, Danilo Rezende 和 Koray Kavukcuoglu。
《用于学习对象、关系与物理的交互网络》。 *NeurIPS*, 2016。3, 8

Yonatan Bisk, Kevin J. Shih, Yejin Choi 和 Daniel Marcu。在丰富的三维块状世界中学习可解释的空间操作。收录于 *AAAI*, 2018。3

Blender在线社区。Blender——一款3D建模与渲染软件包。Blender基金会，Blender研究所，阿姆斯特丹，2016。网址：<<http://www.blender.org>>。4

Christopher B. Burgess, Loic Matthey, Nicholas Watters, Rishabh Kabra, Irina Higgins, Matt Botvinick 和 Alexander Lerchner。《Monet：无监督场景分解与表示》。 *arXiv 预印本 arXiv:1901.11390*, 2019。9

Fabian Caba Heilbron, Victor Escorcia, Bernard Ghanem 和 Juan Carlos Niebles。Activitynet：用于人类活动理解的大规模视频基准测试。发表于 *CVPR*, 2015。2

曹庆星、梁晓丹、李百玲、李冠斌和林亮。基于通用依存树的视觉问题推理。发表于 *CVPR*, 2018。3

Michael B. Chang, Tomer Ullman, Antonio Torralba 和 Joshua B. Tenenbaum。一种基于对象的物理动力学学习组合方法。载于 *ICLR*, 2017。3

Erwin Coumans。子弹物理引擎。开源软件： <http://bulletphysics.org>, 2010。4

弗雷德里克·埃伯特、切尔西·芬恩、亚历克斯·X·李和谢尔盖·莱文。基于时间跳跃连接的自监督视觉规划。发表于 *CoRL*, 2017。3

陈友凡、张晓凡、张舒、王文生、张驰和黄恒。异构记忆增强的多模态注意力模型用于视频问答。 *CVPR*, 2019。5

切尔西·芬恩、伊恩·古德费洛和谢尔盖·莱文。基于视频预测的物理交互无监督学习。发表于 *NeurIPS*, 2016。3

Amy Fire 与 Song-Chun Zhu. 从视频中学习感知因果关系。 *TIST*, 7(2):23,2016。 3

Katerina Fragkiadaki, Pulkit Agrawal, Sergey Levine 和 Jitendra Malik. 《为台球游戏学习物理学视觉预测模型》。载于 *ICLR*, 2016。 3

甘哲、甘创、何晓东、蒲云辰、Kenneth Tran、高建峰、Lawrence Carin 和邓丽。视觉描述的语义组合网络。 *CVPR*, 2017。 2

高继阳、孙晨、杨振恒与 Ram Nevatia. 《Tall: 通过语言查询实现时间活动定位》。 *ICCV*, 2017。 2

托比亚斯·格斯坦伯格、诺亚·D·古德曼、大卫·A·拉尼亚多与约书亚·B·特南鲍姆。《如何、是否、为何：因果判断作为反事实对比》。载于 *CogSci*, 2015。 1

Rohit Girdhar 和 Deva Ramanan. Cater: 用于组合操作与时间推理的诊断数据集。2020。 3

塞尔吉奥·瓜达拉马、尼维达·克里希纳莫尔蒂、吉里什·马尔卡内卡尔、苏巴希尼·维努戈帕兰、雷蒙德·穆尼、特雷弗·达雷尔和凯特·萨恩科。YouTube2text: 利用语义层次结构和零样本识别技术识别与描述任意活动。发表于 *ICCV*, 2013。 2

何凯明、张翔宇、任少清和孙健。图像识别的深度残差学习。收录于 *CVPR*, 2016。 6, 8

何开明、乔治亚·吉基奥亚里、彼得·多尔ár, 以及 Ross Girshick. Mask R-CNN. In *ICCV*, 2017。 8

丽莎·安妮·亨德里克斯、奥利弗·王、埃利·谢赫特曼、约瑟夫·西维奇、特雷弗·达雷尔和布莱恩·拉塞尔。利用自然语言对视频中的时刻进行本地化。发表于 *ICCV*, 2017。 2

塞普·霍克赖特和 Jürgen Schmidhuber. 长短期记忆. *神经计算*, 9(8): 1735–1780,1997. 5

荣航·胡、雅各布·安德烈亚斯、马库斯·罗尔巴赫、特雷弗·达雷尔和凯特·萨恩科。《学会推理：用于视觉问答的端到端模块网络》。 *CVPR*, 2017。 3

Drew A. Hudson 与 Christopher D. Manning. 机器推理的组合注意力网络。 *ICLR*, 2018。 3, 6

德鲁·A·哈德森与克里斯托弗·D·曼宁。GQA: 用于现实世界视觉推理与组合式问答的新数据集。发表于 *CVPR*, 2019。 1, 2

张云硕、宋 Yale、俞英在、金英珍与金根熙。TGIF-QA: 面向视觉问答中的时空推理。收录于 *CVPR*, 2017。 1, 2, 3

贾斯汀·约翰逊、巴拉特·哈里哈兰、劳伦斯·范德马滕、李飞飞、C·劳伦斯·齐特尼克和罗斯·吉尔希克。CLEVR: 用于组合语言与基础视觉推理的诊断数据集。发表于 *CVPR*, 2017a。 1、2、3、4、6

贾斯汀·约翰逊、巴拉特·哈里哈兰、劳伦斯·范德马滕、朱迪·霍夫曼、李飞飞、C·劳伦斯·齐特尼克和罗斯·吉尔希克。视觉推理的程序推断与执行。收录于 *ICCV*, 2017b。 3, 6

Will Kay, Joao Carreira, Karen Simonyan, Brian Zhang, Chloe Hillier, Sudheendra Vijayanarasimhan, Fabio Viola, Tim Green, Trevor Back, Paul Natsev, 等. 人类动作视频动力学数据集. *arXiv:1705.06950*,2017. 2

Diederik P. Kingma 与 Jimmy Ba. Adam: 一种 Stochastic Optimization 方法。In *ICLR*, 2015。 15

杰雷、吕立成、莫希特·班萨尔和塔玛拉·L·伯格。TVQA: 本地化、组合式视频问答。载于 *EMNLP*, 2018。 2、3、5、7

Adam Lerer、Sam Gross 和 Rob Fergus. 通过示例学习积木塔的物理直觉。发表于 *ICML*, 2016。 3

李云珠、吴佳军、朱俊燕、Joshua B. Tenenbaum、Antonio Torralba 和 Russ Tedrake。基于部分观测的模型控制传播网络。 *ICRA*, 2019。8

林宗义、彼得·多尔ár、Ross Girshick、Kaiming He、Bharath Hariharan 和 Serge Belongie。用于目标检测的特征金字塔网络。 *CVPR*, 2017。8

毛家园、甘创、普什米特·科利、Joshua B. Tenenbaum 和吴佳军。《神经符号概念学习者：基于自然监督对场景、词语和句子的解读》。 *ICLR*, 2019。9

David Mascharka、Philip Tran、Ryan Soklaski 和 Arjun Majumdar。《基于设计的透明性：弥合视觉推理中性能与可解释性之间的差距》。 *CVPR*, 2018。3, 6

托马斯·米科洛夫、伊利亚·苏茨克韦尔、凯·陈、格雷格·S·科拉多和杰夫·迪恩。词语与短语的分布式表征及其组合性。载于 *NeurIPS*, 2013。5

Ishan Misra、Ross Girshick、Rob Fergus、Martial Hebert、Abhinav Gupta 和 Laurens van der Maaten。通过提问进行学习。发表于 *CVPR*, 2018。3

Roozbeh Mottaghi、Mohammad Rastegari、Abhinav Gupta 和 Ali Farhadi。《如果.....会发生什么？——学习预测图像中力的作用效果》。发表于 *ECCV*, 2016。3

Mun Jonghwan、Seo Paul Hongsuck、Jung Ilchae 和 Han Bohyung。MarioQA：通过观看游戏视频回答问题。发表于 *ICCV*, 2017。2, 3

Judea Pearl. *因果关系*. 剑桥大学出版社, 2009.3

Ethan Perez、Florian Strub、Harm De Vries、Vincent Dumoulin 和 Aaron Courville。FiLM：基于通用条件层的视觉推理。发表于 *AAAI*, 2018。3

亚当·桑托罗、大卫·拉波索、大卫·G·T·巴雷特、马特乌什·马利诺夫斯基、拉兹万·帕斯卡努、彼得·巴塔利亚和蒂莫西·利利克拉普。《用于关系推理的简单神经网络模块》。 *NeurIPS*, 2017。3

田佳邵、Aron Monszpart、郑友益、Koo邦金、徐伟伟、周坤与Niloy J. Mitra。《想象不可见之物：基于稳定性的长方体场景理解排列》。 *ACM TOG*, 33(6), 2014。3

施兴建、陈周荣、王浩、叶迪彦、黄外金和吴旺春。卷积LSTM网络：一种用于降水nowcasting的机器学习方法。载于 *NeurIPS*, 2015。6

Elizabeth S. Spelke. 核心知识. *美国心理学杂志*, 55(11):1233,2000.1

Joseph Suarez、Justin Johnson 和 Fei-Fei Li。DDRprog：一款基于 Clevr 的可微分动态推理编程器。 *arXiv: 1803.11361*, 2018。3

Makarand Tapaswi、Yukun Zhu、Rainer Stiefelhausen、Antonio Torralba、Raquel Urtasun 和 Sanja Fidler。MovieQA：通过问答理解电影中的故事。收录于 *CVPR* 2016。
1, 2, 3

汤默·大卫·乌尔曼。关于直觉理论的本质与起源：学习、物理学与.....
心理学。博士论文，Massachusetts Institute 理工大学，2015。1

布沙希尼·维努戈帕兰、马库斯·罗尔巴赫、杰弗里·多纳休、雷蒙德·穆尼、特雷弗·达雷尔和凯特·萨恩科。序列到序列：视频到文本。发表于 *ICCV*, 2015。2

尼古拉斯·沃特斯、安德烈亚·塔凯蒂、西奥法内·韦伯、拉兹万·帕斯卡努、彼得·巴塔利亚和丹尼尔·佐兰。视觉交互网络：从视频中学习物理模拟器。载于 *NeurIPS*, 2017。3

Jiajun Wu、Joshua B. Tenenbaum 和 Pushmeet Kohli。Neural Scene 反向渲染。In *CVPR*, 2017。8

杨广宇、Igor Ganichev、王晓静、Jonathon Shlens 和 David Sussillo。基于工作记忆的视觉推理数据集与架构。收录于 *ECCV*, 2018。2, 3

杨子超、何晓东、高建峰、邓莉和 Alex Smola。用于图像问答的堆叠注意力网络。发表于 *CVPR*, 2016。3

田业、王晓龙、James Davidson 和 Abhinav Gupta。可解释的直观物理模型。收录于 *ECCV*, 2018。3

易克欣、吴佳军、甘创、安东尼奥·托拉尔巴、普什米特·科利和约书亚·B·特南鲍姆。神经符号 VQA：从视觉与语言理解中分离推理。载于 *NeurIPS*, 2018。3、7、8

Amir Zadeh、Michael Chan、Paul Pu Liang、Edmund Tong 和 Louis-Philippe Morency。Social-IQ：一种用于评估人工社会智能的问答基准。发表于 *CVPR*, 2019。1、2、3

Rowan Zellers、Yonatan Bisk、Ali Farhadi 和 Yejin Choi。从识别到认知：视觉常识推理。收录于 *CVPR*, 2019。2, 3

陈朱、赵彦鹏、黄帅毅、涂克伟和马毅。视觉问答中的结构化注意力机制。收录于 *ICCV*, 2017。3

朱玉克、奥利弗·格罗特、迈克尔·伯恩斯坦与李飞飞。Visual7w：基于图像的扎根式问答。收录于 *CVPR*, 2016。1

补充材料

A 描述性问题子类型及统计信息

Clevrer中的描述性问题包含五种子类型。在生成这些问题时，我们平衡了每种问题子类型中答案的出现频率，以减少偏差。各子类型的答案空间分布如图6所示。




图6: 描述性问题子类型及答案空间统计。

B NS-DR模型详细信息及训练范式

本文进一步详细阐述了NS-DR模型及其训练范式。该模型的运行示例可参见图7。

视频帧解析器。我们的帧解析器是在从训练视频中随机选取的4,000帧数据上进行训练的，这些数据包含每帧中所有物体的真实掩码及属性标注。我们采用随机梯度下降算法对模型进行了30,000次迭代训练，批量大小为6，学习率为0.001。在测试阶段，我们保留置信度得分大于0.9的物体候选框，并利用这些候选框构建视频的物体级抽象表示。

神经动力学预测器。PropNet中的对象编码器 f_{encO} 和关系编码器 f_{encR} 均采用卷积神经网络实现，并输出一个 D_{enc} 维向量作为表征。我们在每个对象的对象编码器 f_{encO} 与预测器 f_{predO} 之间添加了跳跃连接，以生成更高质量的图像。同时，我们还引入了关系预测器 f_{predR} ，用于判断两个对象在下一个时间步是否会发生碰撞。

在时间 t ，我们首先对对象和关系 $coi_t = f_{encO}(o_{i,t})$ 、 $crk_t = f_{encR}(o_{u_k,t}, o_{v_k,t}, ark_t)$ 进行编码，其中 $o_{i,t}$ 表示时间 t 的对象 i 。随后，我们将传播步骤 l 中关系 k 产生的传播效应记为 elk_t ，对象 i 产生的效应记为 hli_t 。对于步骤 $1 \leq l \leq L$ ，传播过程如下：

该流程可描述为步骤4。

$$h0i_t = \mathbf{0}, i = 1 \dots jOj, \quad (7)$$

步骤 $l = 1, \dots, L$:

$$\begin{aligned} e_{k,t}^l &= f_R(c_{k,t}^r, h_{u_k,t}^{l-1}, h_{v_k,t}^{l-1}), \quad k = 1 \dots |R|, \\ h_{i,t}^l &= f_O(c_{i,t}^o, \sum_{k \in \mathcal{N}_i} e_{k,t}^l, h_{i,t}^{l-1}), \quad i = 1 \dots |O|, \end{aligned} \quad (8)$$

输出:

$$\begin{aligned} \hat{r}_{k,t+1} &= f_R^{pred}(c_{k,t}^r, e_{k,t}^L), \quad k = 1 \dots |R|, \\ \hat{o}_{i,t+1} &= f_{predO}(coi_t, hLi_t), \quad i = 1 \dots jOj \end{aligned} \quad (9)$$

其中 f_O 表示对象传播子， f_R 表示关系传播子， $\mathcal{N}_i$ 表示关系集，其中对象 i 为接收方。神经动力学预测器通过随机梯度下降法最小化预测值 $\hat{r}_{k,t+1}$ 、 $\hat{o}_{i,t+1}$ 与真实未来观测值 $r_{k,t+1}$ 、 $o_{i,t+1}$ 之间的 $\mathcal{L}_2$ 距离进行训练。




图7: NS-DR在clever数据集上的样本结果。‘Pred.’和‘CF.’分别表示由模型动态预测器提取的预测事件与反事实事件。本示例中展示的反事实条件为移除青色圆柱体。

神经动力学预测器的输出为 $\langle \{^{\wedge}Ot\}_{t=1\dots T}, \{^{\wedge}Rt\}_{t=1\dots T} \rangle$, 即包含所有观测帧和模拟渲染帧中对象状态与关系的集合。通过该表示, 我们可以恢复不同模拟条件下对象的完整运动与事件轨迹, 并生成视频的动态场景表征。例如, 若需了解场景中移除某个对象后会发生什么, 只需从图中删除对应的顶点及其关联边, 并利用学习到的动力学模型进行模拟渲染即可获得轨迹。

我们的神经动力学预测器是在帧解析器提供的对象掩码和属性上进行训练的。我们通过跨不同帧匹配对象内在属性并保留出现在10个以上帧中的对象提案, 来过滤不一致的对象提案。对于时长为125秒的视频, 我们将采样5个播放片段, 每个片段包含从原始视频均匀采样的25帧画面。我们将输入数据归一化至[-1,1]范围, 并在大小为3的时间窗口内进行拼接。设置传播步长 L 为2, 传播效应维度 D_{enc} 为512。采用Adam优化器 (Kingma & Ba, 2015), 初始学习率为 10^{-4} , 每3个训练周期衰减因子为0.3。模型以批量大小2训练9个周期。**问题解析器。**对于开放式描述性问题, 问题解析器基于随机选取的不同数量的问题-程序对进行训练; 而对于选择题问题, 则分别独立训练问题解析器和选项解析器。使用 n 个样本进行训练, 意味着使用从多项选择题 (涵盖所有三种题型) 中随机抽取的 n 个问题来训练问题解析器, 随后从同一题库中抽取 $4n$ 个选项来训练选项解析器。所有模型均采用Adam优化器 (Kingma & Ba, 2015) 进行训练, 迭代次数为30,000次, 批量大小为64, 学习率为 7×10^{-4} 。

程序执行器。NS-DR程序执行器中所有模块的完整列表汇总于表4和表5。各模块的输入与输出数据类型汇总于表6。

C 来自 CLEVRER 的额外示例

我们在图8中展示了来自clever的更多示例。此外, 图9至图11展示了不同类型问题的提问/选择程序可视化结果。完整数据集可供下载。

模块类型	名称/描述	输入类型	输出类型
输入 模块	物体	-	目标
	返回视频中的所有对象	-	事件
	事件	-	事件
	返回视频中发生的所有事件。	-	事件
	未见事件	-	事件
	返回视频结束后所有未来的事件。	-	事件
	所有活动	-	事件
	返回任何对象上或对象之间所有可能发生的事件。	-	事件
对象 过滤器 模块	开始	-	事件
	返回特殊的“开始”事件。	-	事件
	最后部分	-	事件
	返回特殊的“结束”事件。	-	事件
	滤镜颜色	(对象, 颜色)	目标
	从输入列表中选择具有指定颜色的过滤材质对象	(对象, 材料)	目标
	从输入列表中选择符合输入材质“Filter shape”条件的对象	(对象, 形状)	目标
	从输入列表中选择对象, 并使用输入形状过滤器进行移动	(对象, 帧)	目标
事件 过滤器 模块	选择输入帧中所有移动对象	(对象, 帧)	目标
	或整个视频 (当输入帧为“null”时); 滤波	(对象, 帧)	目标
	器静止状态	(对象, 帧)	目标
	选择输入帧中的所有静止物体	(对象, 帧)	目标
	或整个视频 (当输入帧为“null”时)	(对象, 帧)	目标
	过滤器 -	事件 (事件对象)	事件
	选择输入对象的所有传入事件	事件 (事件对象)	事件
	过滤掉	事件 (事件对象)	事件
事件 过滤器 模块	选择输入对象的所有退出事件	事件 (事件对象)	事件
	过滤器冲突	事件 (事件对象)	事件
	选择所有涉及任一输入对象的碰撞。	事件 (events, event)	事件
	前滤镜	事件 (events, event)	事件
	选择目标事件之前的所有事件	事件 (events, event)	事件
	过滤器后	事件 (events, event)	事件
	选择目标事件之后的所有事件	事件 (events, event)	事件
	过滤顺序	(事件, 顺序)	事件
事件 过滤器 模块	按特定时间顺序选择事件	事件 (events, event)	事件
	过滤祖先	事件 (events, event)	事件
	选择输入事件的所有因果祖先	事件	框架
	获取帧	事件	框架
	返回视频中输入事件的帧。	事件	框架
	获取反事实	(事件, 对象)	事件
	选择对象被移除后将发生的所有事件。	(事件, 对象)	目标
	获取合作方	(事件, 对象)	目标
事件 过滤器 模块	返回输入对象的碰撞对象 (输入事件必须为碰撞事件)	(事件, 对象)	目标
	获取对象	事件	目标
	返回参与输入事件的对象 (输入事件必须为传入/传出事件)	事件	目标
	唯一的	事件 / 目标	事件 / 目标
	返回输入列表中唯一的事件/对象。	事件 / 目标	事件 / 目标

表4: NS-DR程序执行器的功能模块。

模块类型	名称/描述	输入类型	输出类型
输出：产出 模块	查询颜色 返回输入对象的颜色。	目标	颜色、材
	查询材料 返回输入对象的材质。	目标	质、形状
	查询形状 返回输入对象的形状。	目标	质、形状
	计数 返回输入对象的数量。	目标	肠管； 肠段
	存在：存在 如果输入对象不为空，则返回 “yes” 。	对象（事件，	布尔型
	属于		布尔型
	如果输入事件属于否定事件集，则返回 “yes” 。	事件）bool	布尔型
	返回输入布尔值的反值。		

表5：NS-DR程序执行器的功能模块（续）。

数据类型	描述
目标	一本存储视频中对象固有属性的词典
目标	对象列表
事件	一本记录事件类型、帧及参与对象的字典
事件	事件列表
次序	一个字符串，用于指示事件的时间顺序（选项包括 “第一”、“第二” 和 “最后”）。
颜色	一个字符串，用于指定 “灰色”、“棕色”、“绿色”、“红色”、“蓝色”、“紫色”、“黄色” 或 “青色” 中的颜色。
布料	一个字符串，用于指示材料类型为 “金属” 或 “橡胶”。
形状	一个字符串，用于指定 “立方体”、“圆柱体” 或 “球体” 中的某种形状。
框架	表示事件帧编号的整数

表6：程序执行器中各模块的输入/输出数据类型。

问题：“视频结束时有多少个球体在运动？”

```

计数(
  Filter_move (Filter_shape (Objects, "Sphe-
    re" ),
    获取帧（结束）
  )
)

```

问题：“当金属球进入场景时，是否存在静止的球体？”

存在：存在性）

```

Filter_stationary (Filter_shape (Objec-
  ts, "Sphere" ), Query_frame(
    Filter_in (事件,
      Filter_shape(
        过滤器/材质 (对象, "金属" ), "球
        体"
      )
    )
  )
)

```

问题：“第二个与绿色物体发生碰撞的物体是什么形状？”

```

Query_shape (Get_col_
  partner(
    Filter_order (Filter_
      collision(
        事件,
        Filter_color (对象, "绿色" )
      )
    "第二"),
    Filter_color (对象, "绿色" )
  )
)

```

问题：“与蓝色物体相碰撞的物体是什么颜色？”

```

查询颜色 (Get_col_
  partner(
    FilterCollision (事
      件,
      Filter_color (对象, "蓝色" )
    )
    Filter_color (对象, "蓝色" )
  )
)

```

图 9：描述性问题程序示例。

问题：“以下哪一项不是导致金属球与橡胶球发生碰撞的原因？”
否定 (Belong_to)

```

事件, // 选择程序的输出
Filter_ancestor(
  Filter_collision(
    FilterCollision
    ( 事件, Filter_shape(
      过滤器/材质 (对象, “金属” ), “球体”
    )
  ),
  Filter_shape (Filter_material (Objects, “橡胶” ),
    “球体” )
)
)
)

```

选择：“绿色立方体与橡胶球之间的碰撞”

```

FilterCollision(
  FilterCollision
  ( 事件, Filter_shape(
    Filter_color (对象, “立方体” ),
    “立方体”
  )
),
  Filter_shape (Filter_material (Objects, “橡胶” ),
    “球体” )
)

```

选项：“绿色立方体正在进入场景” Filter_in(

```

  Filter_shape ( Filter_color (Objects,
    “Green” ),
    “立方体”
  )
)

```

图10：解释性问题及选择题程序示例。

反事实问题：“如果移除橡胶球，会发生什么事件？”

```

Belong_to(
  事件, // 选择程序的输出
  Get_counterfact(
    Filter_shape(
      过滤器/材质 (对象, “橡胶” ), 球体
    )
  )
)

```

选项：“立方体与金属球发生碰撞” Filter_collision(

```

  FilterCollision
  (AllEvents)
  Filter_shape (对象, “立方体” )
  Filter_shape (Filter_material (Objects,
    “Metal” ) )
    “球体” )
)

```

预测性问题：“接下来会发生什么？” Belong_to(

```

  事件, // 选择程序的输出
  未见事件)

```

选项：“金属球与圆柱体发生碰撞” Filter_collision(

```

  FilterCollision
  (AllEvents)
  Filter_shape ( Filter_material (Objects,
    “Metal” ), “Sphere” )
  )
  Filter_shape (对象, “圆柱体” )
)

```

图11：预测性/反事实问题及选择程序示例。