

Pixel2Phys: 从视觉动态中提炼支配性规律

李瑞坤^{2†}、姚俊^{1,3†}、华英凡¹、唐世祥^{1,4}、齐碧清¹、刘斌³、欧

阳万利^{1,4}、卢燕^{1,4‡}

¹上海人工智能实验室²清华大学

³中国科学技术大学⁴香港中文大学

摘要

直接从高维视觉数据中发现物理定律是人类长期追求的目标，但对机器而言仍是一项艰巨挑战，这体现了科学智能的核心目标。该任务本身极具难度，因为物理知识具有低维度和结构化特征，而原始视频观测数据则具有高维度且冗余性强——大多数像素几乎不携带或完全不携带物理意义。**从这类噪声数据中提取简洁且具有物理相关性的变量，仍是当前研究的关键难题。**为解决这一问题，我们提出了Pixel2Phys——一个可适配任何多模态大语言模型（MLLM）的协作式多智能体框架。该框架通过采用结构化工作流程，迭代生成、验证和优化假设，模拟人类的科学推理过程，从而提取形式化的物理知识。通过对高维数据反复构建并优化候选方程，该框架能够识别出最能准确捕捉底层物理演变过程的简洁表征。这种自动化探索过程模拟了人类科学家的迭代工作流程，使人工智能能够直接从原始观测数据中推导出可解释的支配方程。在各类模拟及真实物理视频中，Pixel2Phys均能发现精确且可解释的支配方程，并在基线快速发散的区域保持稳定的长期外推结果。

1. 引言

从观测数据中发现物理定律是科学理解的核心，历史上这一过程推动了物理学、天文学及自然科学领域的重大进展[1, 7, 39, 44]。随着人工智能系统日益融入科学工作流程[28, 48]，能够直接从视觉观测中推导出支配性方程，已成为实现真正“科学人工智能”的关键步骤。Hu-

人类科学家通常通过从复杂的视觉现象中提炼出结构化、低维的物理变量，并制定简洁的符号化定律来实现此类发现[9, 32]。然而，这一手动过程既缓慢又费时费力——诸如将第谷·布拉赫的天文观测数据转化为开普勒定律这样的经典案例，就需要数十年的专业推理工作。因此，实现这一能力的自动化——即**视觉方程发现**——将加速科学进步。

然而，视觉方程发现极具挑战性，因为视频中的真实物理信号具有低维度和简洁性，但它们被淹没在大量视觉无关内容中——例如纹理、光照变化和背景运动[]。这些冗余成分主导了像素空间，掩盖了科学定律所依赖的紧凑物理结构。先前的方法已尝试通过多种方式解决这一难题，但每种方法都存在根本性局限：

(1) 监督式方程预测模型[2, 24, 35, 48]：能够直接从视频中预测方程，但需要人工整理的方程-视频数据对进行训练，而此类数据极为稀缺，导致模型在训练所针对的具体系统之外泛化能力较差；(2) 无监督潜在在编码方法：首先利用自动编码或预测目标从视频中学习潜在表示[5, 15–17, 25, 46]，随后对这些潜在表示应用符号回归。然而，由于潜在空间是由重建或下一帧预测优化过程而非物理结构决定的，它们往往具有非唯一性，容易将视觉上显著但物理上无关的因素相互交织。(3) 近期的多模态大语言模型（MLLMs）将视觉理解与强大的符号推理相结合，展现出方程发现的潜力[3, 4, 26]。但直接提示 MLLM 模型主要会从其训练语料库中检索并重组先验知识；若缺乏结构化工作流程，该模型难以仅凭原始视觉数据推断新的物理变量或推导出物理定律。这些挑战凸显了开发一种能够可靠提取隐藏在视觉数据中具有物理意义结构的方法的必要性。

*在上海人工智能实验室实习期间完成的工作。†贡献相同。

‡通讯作者（luyan@pjlab.org.cn）




图1. 从视频中提取的流体动力学基本定律。(a) 运动物体的轨迹动力学。(b) 时变物理场的时空动力学。(c) 物理现象的内在动力学。

支持高维视频处理，并助力新方程的发现。

为应对这些挑战，我们提出了Pixel2Phys——一个协作式多智能体框架，可与任何 MLLM 配合使用，并将视觉方程发现过程组织成结构化、迭代式的科学工作流程（图2 a）。该框架的核心是计划智能体，它协调三个专业智能体：变量智能体、方程智能体和实验智能体，并在迭代过程中确定优化策略。变量智能体通过多种互补的专用工具从视频中提取物理量，这些工具对应不同类别的物理系统，使其能够还原物体级运动、场级演化以及其他常构成控制方程基础的低维结构。方程智能体则通过动态运用符号回归组件（例如调整稀疏约束强度或选择不同的符号库）来生成候选方程。实验代理通过多项指标对每个候选方程进行评估，包括模拟其预测动力学行为、测量重构偏差、测试时间外推能力，并将这些结果汇总成结构化的报告提交给计划代理。计划代理整合这些报告后，会发出针对性指令——例如要求方程代理强化稀疏性，或要求变量代理纳入动力学约束条件——以指导后续优化步骤。通过这种假设提出、评估与调整的迭代循环，Pixel2Phys能逐步剔除视觉上无关的因素，最终聚焦于最能描述真实底层动力学的变量与方程。关键在于，该工作流程的每个步骤均具备自动化特性，完全符合现代多层语言模型（MLLM）的执行能力，从而使Pixel2Phys能够将模型强大的单步推理能力与结构化的多步协调机制相结合，从而发现超出模型训练数据范围的新变量及主导性方程。我们针对三类难度递增的物理视频对本框架进行了评估。结果表明，通过提炼出准确且易于解读的指导性等式——

在各项改进措施中，我们提出的框架提升了外推准确性。准确率（RMSE）较基线提升了45.35%。我们的贡

献可概括如下：

- 我们提出了一种新型的多智能体框架用于视觉方程发现，该框架中 MLLM 规划器协调各专用智能体，以多粒度层级解析复杂的视觉动态。
- 我们设计了一种迭代式协同优化推理流程，该流程打破了视觉表征学习与法律发现之间的循环依赖关系。
- 针对三类具有挑战性的物理视频开展的大量实验表明，我们的框架不仅能发现具有物理可解释性的主导方程，还能将长期外推精度提高45.35%。

2. 相关工作

2.1. 从视频中推断物理现象

现有的方法通常从两个视角处理视觉动态问题。第一类方法聚焦于**隐式神经动态**，通过学习潜在表征来进行未来预测。诸如Neural ODEs[10, 17]和Koopman算子[5]等模块常被用于建模连续演化过程。其他研究则将视频分解为PDE动态[15, 46]或解耦表征[13, 47]。尽管这些方法在预测方面效果显著，但它们将物理定律封装在黑盒网络中，缺乏明确的可解释性。第二类方法——**物理信息感知**——具有强烈的归纳偏置。研究人员利用逆向图形[20]或施加刚体约束[22]来推断质量、摩擦力等特定属性。然而，这些方法高度依赖对控制方程的先验知识，限制了其从陌生物理现象中发现未知定律的能力。

2.2. 视觉方程发现

从视频中发现方程是一个新兴领域，通常遵循两种范式：(1) **基于流水线的方法**

方法[30, 49]通过提取物体的显式轨迹后应用符号回归。这些方法依赖预训练的跟踪器，但在物体未定义连续场（如流体）场景中表现不佳。(2)终端到终端方法[8, 41]通过学习潜在坐标空间进行方程回归。然而，它们面临一个关键的循环依赖关系：构建优质变量空间需要了解动力学特性，而确定动力学特性又依赖于清晰的变量空间。因此，在复杂视觉场景中，这些方法往往只能获得次优解。我们的工作提出了第三种范式：即协作式多智能体框架。通过建立推理驱动的反馈循环，我们使变量提取与方程发现能够相互优化，有效打破循环依赖关系，并将发现能力扩展至多样化的视觉动态场景。

3. 问题表述

在从高维数据中推断支配性规律的任务中，目标是找到一个简洁且精确的符号表达式。我们获得了一系列高维视觉观测数据（即一段视频）。 $\{\mathbf{X}(t)\}_{t=1}^N$ ，其中每一帧 $\mathbf{X}(t) \in \mathbb{R}^D$ （ D 为像素空间，例如 $C \times H \times W$ ）。我们假设该视频观测到了一个基于内在流形[8]、在 $Z \subset \mathbb{R}^d$ 上演化的未知低维动力系统，其中 $d \ll D$ 。我们的目标是同时发现内在物理变量 $z(t) \in Z$ 及其对应的符号化控制律 f 。

, which defines the system's evolution, $\frac{dz}{dt} = f(z(t))$ 。这构成了一个具有挑战性的双重发现问题，因为坐标系 z 和函数 f 均未知。该问题可分解为两个相互关联的子问题：

- **物理变量提取。**学习编码器 $\phi: \mathbb{R}^D \rightarrow \mathbb{R}^d$ ，该编码器将高维视觉观测 $\mathbf{X}(t)$ 映射到其对应的内在物理状态 $z(t) = \phi(\mathbf{X}(t))$ 。为确保 $z(t)$ 具有信息代表性，该组件通常包含解码器 $\psi: \mathbb{R}^d \rightarrow \mathbb{R}^D$ ，用于施加重构约束 $\mathbf{X}(t) \approx \psi(z(t))$ 。
- **适用法律：蒸馏法。**从候选函数库 Θ （例如多项式、三角函数项）中，为动态函数 f 找到一个可解释的符号表达式。该函数必须准确模拟所提取变量 $z(t)$ 的变化规律。

这些组件之间的协同效应是核心挑战。提取出的变量 $z = \phi(\mathbf{X})$ 的质量直接决定了所提炼出的规律 f 的简洁性与准确性。反之，一个简洁且稀疏的规律 f 会提供强有力的信号来指导变量提取过程 ϕ ，促使该过程过滤掉动态无关的视觉组件。我们的框架旨在解决这一协同优化问题，寻找一对自洽的变量与规则组合。

intrinsic variable space Z and its symbolic law f that fit the observed data and generalize for long-term prediction.

4. 方法

4.1. Pixel2Phys 方法概述

Pixel2Phys框架模拟了人类科研团队的协作工作流程，用于解决第3节中定义的双重发现问题，该过程包括观察、假设、实验和优化。如图2所示，Pixel2Phys由四个具有不同角色的智能体组成：计划智能体作为团队的核心协调者，负责设定目标、分析报告、诊断瓶颈，并向其他智能体提供 $\mathcal{I}_{\text{plan}}$ 指令提示以指导下一代；变量智能体执行视觉解析任务，即从高维观测数据 $\mathbf{X}(t)$ 中解析并提取低维物理变量 $z(t)$ ；方程智能体负责从 $z(t)$ 中提炼出符号控制方程 f ；最后，实验智能体验证当前 (Z, f) 数据对的质量。在每次迭代中，变量代理、方程代理和实验代理需要分别向计划代理返回一份报告（分别标记为 $\mathcal{R}_{\text{var}}$ 、 $\mathcal{R}_{\text{equ}}$ 和 $\mathcal{R}_{\text{exp}}$ ），其中包含定量性能指标和定性可视化诊断信息，用于指导下一步决策。这些代理均以MLLM的形式实现，并遵循统一协议：它们处理视觉数据 $\mathbf{X}$ 和文本提示 P 以生成文本响应 $\text{MLLM}(\mathbf{X}, P)$ 。算法??展示了Pixel2Phys执行过程的伪代码。

4.2. 计划代理：迭代式全局规划 声纳测深

我们的框架用由计划代理驱动的迭代推理循环取代了简单的流水线。该代理是核心协调器，负责协调变量空间 Z 与控制律 f 的协同优化。

推理循环始于初始化步骤（ $k=0$ ）。计划代理解析用户任务并启动初始迭代，生成候选对 (Z_0, f_0) 及相应的报告 $\mathcal{R}_{\text{var}}^0$ 、 $\mathcal{R}_{\text{equ}}^0$ 和 $\mathcal{R}_{\text{exp}}^0$ 来自每个代理的 x_p 。在后续迭代中（ $k \geq 1$ ），计划代理会汇总这些报告进行双重诊断：首先检查 $\mathcal{R}^{k-1}$ 中的可视化数据以进行定性评估动态保真度随后通过 $\mathcal{R}^{k-1}$ 和 $\mathcal{R}^{k-1}$ 输出仔细分析具体的定量指标，以精确定位具体瓶颈。颈部。基于此分析，系统制定了指导性提示 $\mathcal{I}_{\text{kplan}}$ 以解决已识别的失效模式：

- **变量优化。**当诊断将故障归因于较差的 Z （例如高重建误差）时，计划代理会指示变量代理重新提取 Z 。关键在于，计划代理将提供方程 f_{k-1} 以激活基于物理的损失函数（第4.3节）。




图2. Pixel2Phys的多智能体协作框架。

- **方程优化。**当 Z 被认定为高质量，但 f_{k-1} 不准确或过于复杂时，计划代理会指示方程代理通过调整配置超参数来修改其方程搜索。这一迭代优化循环将持续进行，直到计划代理确定 R 成立。 k_{xp} 符合成功标准（附录??）。最终的 (Z_k, f_k) 配对结果将作为解决方案返回。

4.3. 可变代理：从 V_i 中提取变量

给定一段视频序列 $\mathbf{X}(t)$ ，可变智能体通过部署特定解析工具来提取物理变量 $\mathbf{z}(t)$ 。我们提供了多粒度工具以实现灵活使用，能够处理对象、像素及表征层面呈现的物理信息。该智能体会根据视频的视觉特征以及计划智能体发出的明确指令提示 $\mathcal{I}_{plan}$ 动态选择相应的工具：具体而言，我们为运动物体视频提供对象级工具，为物理场提供像素级工具，并为复杂科学现象提供基于自动编码器的工具。

对象级工具。在移动物体（如天体运行）时，可变代理会提取轨迹 $\mathbf{z}(t) = [x(t), y(t)]$ 。我们采用视觉基础模型进行零样本对象分割与跟踪，以避免

针对物体特定形状进行训练。具体而言，我们采用Segment Anything [23] 在每一帧中对潜在物体进行分割。随后，智能体会过滤掉静态目标（详见附录??），并将移动物体的质心坐标记录为 $\mathbf{z}(t)$ 。

像素级工具。对于由偏微分方程（PDE）描述的物理场（图1 b），视频帧 $\mathbf{X}(t)$ 被视为连续场 $u(\mathbf{x}, t)$ 在像素 $\mathbf{x}$ [7, 45]处离散化的样本。物理动力学源于局部空间相互作用。我们为可变智能体配备固定的卷积核，直接从像素网格计算空间导数，从而得到拉普拉斯算子 Δ 和双调和算子 Δ^2 等算子。由于控制方程在任意像素处均有效，智能体会随机采样稀疏像素子集，以高效收集空间算子作为物理变量 $\mathbf{z}(t) = [u(t), \Delta u(t), \Delta^2 u(t), \dots]$ 。

表示层工具。对于复杂的科学现象，其底层动态常被设备噪声和光照波动所掩盖（图1 c）。我们采用一种新型基于物理原理的自编码器，将 $\mathbf{X}(t)$ 压缩为潜在表示 $\mathbf{z}(t) = \phi(\mathbf{X}(t))$ ，确保底层变量尽可能保持简洁。该工具根据物理先验信息的可用性以两种模式运行：首先，在提供指导性提示时

$\mathcal{I}_{\text{plan}}$ 包含在前一次迭代中发现的控制方程 f ，损失函数由两个部分组成： $L = \mathcal{L}_{\text{recon}} + \lambda_{\text{eq}} \mathcal{L}_{\text{eq}}$ 。第一项是自监督重建误差，确保 z 保留足够的观测信息；第二项代表物理一致性损失，其系数 λ_{eq} 定义为 $\mathcal{L}_{\text{eq}} = \|F(z) - f(z)\|^2$ ，其中 $F(z)$ 表示通过中心差分得到的数值导数，而 $f(z)$ 则是根据方程 f 得出的符号导数。该约束迫使潜在空间遵循控制方程 f ，引导编码器专注于物理动力学特征，同时滤除纹理细节和噪声。其次，在缺乏物理信息的情况下（例如在冷启动阶段），自动编码器仅执行自监督重建任务，其功能与标准自动编码器相同。这种方法确保变量代理能够识别出一个平衡视觉重建与动态简洁性的潜在空间 Z 。关键在于，它使得下游方程代理的输出能够迭代优化物理变量的提取过程。

最后，该流程通过返回提取出的变量 $z(t)$ 及报告 $\mathcal{R}_{\text{var}}$ 来结束。该报告汇总了所使用的具体工具及其超参数配置，例如SAM的模型规模及其掩码尺寸。

4.4. 方程代理：动态符号回归

锡安

考虑到大多数真正的方程..... $\frac{dz}{dt}$ 当函数 $f(z(t))$ 在候选函数的高维空间中呈现稀疏性[6, 8]时，智能体通过三步流程在该函数空间中识别出稀疏的活跃项。

数据与导数估计。给定由离散时间序列 $z(t)$ 构成的状态矩阵 Z ，智能体首先通过数值方法估算时间导数 $\dot{Z}$ 。该步骤采用中心差分法[36] $F(z)$ 以确保方法论一致性，从而建立目标方程的左侧（LHS）。

候选函数库构建。随后，智能体构建候选函数库矩阵 $\Theta(Z)$ ，其中每一列代表状态 $z(t)$ 的某个潜在非线性函数，该函数构成控制方程的右侧（RHS）。候选函数库包含以下组成部分：

- 多项式项包括 $1, z, z^2, z_1 z_2 \dots$ 。
- 超越项包括 $\sin(z), \cos(z), \exp(z), \dots$ 。该方程通过迭代优化过程对候选库进行优化。

稀疏回归与定律蒸馏。该发现任务被表述为求解超定线性方程组。

耳系统 $\dot{Z} \approx \Theta(Z) \Xi$ ，其中 Z 表示导数矩阵， $\Theta(Z)$ 代表候选库， Ξ 为未知的稀疏系数矩阵。优化目标可表述为 $\|Z - \Theta(Z) \Xi\|_{22} + \lambda_{\text{sp}} \|\Xi\|_1$ ，其中第二项强制活性项保持稀疏性。为求解 Ξ ，智能体采用顺序阈值最小二乘法（STLSQ）算法[6]（详见附录??）。稀疏性阈值 λ_{sp} 通过计划智能体指令 $\mathcal{I}_{\text{plan}}$ 确定，从而对发现规律的简约性进行主动引导。最终， $\Xi = [\xi_1, \xi_2, \dots, \xi_d]$ 中的非零元素被重构为符号方程 f 。

最后，该过程通过返回发现的方程 f 以及一份报告 $\mathcal{R}_{\text{equ}}$ 来结束，该报告包含候选库及用于计划代理决策的稀疏性阈值 λ_{sp} 。

4.5. 实验代理：方程评估与反馈

实验代理的职责是严格验证当前迭代中发现的 (Z, f) 配对的质量与一致性。它接收时间序列变量 $z(t)$ 及符号规则 f ，并为计划代理生成多维评估报告 $\mathcal{R}_{\text{exp}}$ 。该验证协议主要评估三个关键方面。

方程质量。为评估支配性法则 f ，实验代理计算两个定量指标：(1) R^2 分数，通过比较数值导数 $F(z)$ 与符号导数 $f(z)$ ；(2) 复杂度，以系数矩阵 Ξ 的项数 L_0 衡量。

变化质量。实验代理会生成轨迹 $z(t)$ 的相图，以直观呈现变量空间的特征。简洁的控制律通常表现为结构化的混沌吸引子，而噪声或缠绕的轨迹则表明存在显著干扰。该图像会被传递给规划代理，由其通过视觉评估轨迹是否具有清晰、低维的动力学结构。

外推保真度。智能体通过从初始条件 $z(0)$ 积分所发现的规律 f ，进行长期数值模拟 $z_{\text{pred}}(t)$ 。随后，它(1)计算预测值 $z_{\text{pred}}(t)$ 与从保留的未来帧 $z_{\text{gt}}(t)$ 中提取的变量在未观测时间范围内的均方根误差（RMSE）；(2)可视化预测轨迹与真实轨迹的曲线图。自洽的配对 (Z, f) 可生成可靠的长期预测结果。

最后，实验代理将所有这些定量指标（ R^2 、 L_0 、RMSE）及图表数据整合到结构化报告 $\mathcal{R}_{\text{exp}}$ 中（具体结构详见附录??）。




图3. 运动物体的推理结果：蓝色线条为真实轨迹；绿色虚线为 PixelsPhys 推断出的轨迹。

表1. 不同种子条件下运动物体在5次运行中的平均性能。最佳结果以粗体显示。

情况	方法	条款建立	假的积极方面:	$R^2@1000$
线性的	AE-SINDy	-	-	0.0046 ± 0.0028
	隐式常微分方程	-	-	0.0154 ± 0.0081
	坐标方程	是	1.100 ± 0.3600	0.8647 ± 0.0554
	Pixel2Phys	是	0	0.9913 ± 0.0000
立方体	AE-SINDy	-	-	0.0720 ± 0.0122
	隐式常微分方程	-	-	0.0039 ± 0.0013
	坐标方程	不是	3.400 ± 1.2800	0.2632 ± 0.1928
	Pixel2Phys	不是	0.3900 ± 0.3620	0.9886 ± 0.0082
通告	AE-SINDy	-	-	0.3647 ± 0.0716
	隐式常微分方程	-	-	0.0240 ± 0.0028
	坐标方程	是	0.2000 ± 0.0040	0.9903 ± 0.0057
	Pixel2Phys	是	0	1.0000 ± 0.0000
VDP	AE-SINDy	-	-	0.2483 ± 0.0182
	隐式常微分方程	-	-	0.0433 ± 0.0102
	坐标方程	是	2.3100 ± 0.6590	0.4920 ± 0.1302
	Pixel2Phys	是	0.9900 ± 0.0030	0.9954 ± 0.0047
滑翔机	AE-SINDy	-	-	0.0310 ± 0.0030
	隐式常微分方程	-	-	0.0360 ± 0.0041
	坐标方程	不	2.1800 ± 0.4900	0.9129 ± 0.0102
	Pixel2Phys	不	3.0000 ± 0.0000	0.9995 ± 0.0000

这构成了计划代理下一步推理的基础。

5. 实验

我们对Pixel2Phys在三类跨学科视频上进行了验证：物体运动（物体级）、物理场（像素级）以及科学现象的真实世界记录（表征级）。默认采用GPT-4o作为大语言模型（LLM）的骨干网络。所有实验中Pixel2Phys的配置参数均列于附录??。

5.1. 对象级动态机制的发现

与先前的研究[19、30、41]一致，我们利用物体运动视频来评估模型从高维数据中准确推导符号运动方程的能力。

观察资料。

5.1.1. 数据集

我们在五个动力系统（图3）上进行了验证：线性、三次、圆形、Van Der Pol（VDP）以及滑翔机。这些方程包含线性项、非线性项等多种特征，并具有显著的时间尺度差异[14]，共同构成了涵盖不同难度级别的评估基准。视频生成的具体细节详见附录??。

5.1.2. 设置

我们根据可解释性将基线方法分为两类。第一类编码潜在向量并学习隐式动力学，包括AE-SINDy[8]和LatentODE[10]；第二类显式预测物体坐标以推断其控制方程，以Coord-Equ[30]为代表。我们在前200步进行训练，并使用1000步外推坐标轨迹上的 R^2 评分进行评估。对于AE-SINDy和Latent-ODE，在评估前通过Procrustes分析将其潜在预测与真实坐标对齐（附录??）。此外，对于能够推断符号表达式的方法，我们评估两项与方程相关的指标：1）项识别率：二元评分（是/否），表示所有真实项是否被正确识别；2）假阳性数：最终方程中包含的错误项数量，用于衡量简洁性。

5.1.3. 主要结果

表1和图3揭示了三个关键见解。首先，隐式方法（Latent-ODE 和 AE-SINDy）存在外推崩溃问题（ $R^2 \approx 0$ ）。这从经验上验证了我们多粒度设计的必要性，表明通用表示方法在缺乏显式对象级解析的情况下无法捕捉刚体物理行为。其次，Pixel2Phys展现出更优的简洁性与鲁棒性。与Coord-Equ相比，我们的框架显著降低了误报率，并实现了近乎完美的长期预测效果，所有发现的符号表达式均被成功解析。

表2。长期预测的平均 RMSE 与 VPS（基于5次运行的平均值±标准差）。最佳结果以粗体显示。VPS 阈值为0.5。

方法	Λ - Ω		布鲁塞尔振荡器		菲茨休-那古莫		斯威夫特-霍恩伯格	
	RMSE ↓	VPS@0.5 ↑	RMSE ↓	VPS@0.5 ↑	RMSE ↓	VPS@0.5 ↑	RMSE ↓	VPS@0.5 ↑
黑盒模型								
FNO [27]	0.68 $\pm$ 0.04	477.00 $\pm$ 20.82	415.34 $\pm$ 81.70	19.10 $\pm$ 3.96	0.89 $\pm$ 0.07	116.20 $\pm$ 6.81	11.02 $\pm$ 4.09	52.10 $\pm$ 9.04
UNO [33]	0.42 $\pm$ 0.05	764.80 $\pm$ 16.97	423.64 $\pm$ 82.42	27.30 $\pm$ 4.23	67.41 $\pm$ 5.26	104.00 $\pm$ 13.73	0.48 $\pm$ 0.08	90.80 $\pm$ 5.81
WNO [40]	96.98 $\pm$ 6.35	41.20 $\pm$ 6.10	68.67 $\pm$ 7.80	9.60 $\pm$ 3.67	34.10 $\pm$ 3.09	22.60 $\pm$ 5.24	1.95 $\pm$ 0.39	31.30 $\pm$ 8.93
符号回归模型								
PDE-Find [34]	0.67 $\pm$ 0.00	492.00 $\pm$ 0.00	1.56 $\pm$ 0.00	40.00 $\pm$ 0.00	0.63 $\pm$ 0.00	54.00 $\pm$ 0.00	0.19 $\pm$ 0.00	200.00 $\pm$ 0.00
SGA-PDE [11]	0.92 $\pm$ 0.10	126.60 $\pm$ 6.51	0.14 $\pm$ 0.02	1000.00 $\pm$ 0.00	NaN	NaN	NaN	NaN
LLM-PDE [12]	0.55 $\pm$ 0.04	438.40 $\pm$ 23.20	NaN	NaN	0.62 $\pm$ 0.12	55.90 $\pm$ 4.20	0.69 $\pm$ 0.13	34.30 $\pm$ 13.03
Pixel2Phys	0.03$\pm$0.00	1000.00$\pm$0.00	0.12$\pm$0.01	1000.00$\pm$0.00	0.16$\pm$0.01	1000.00$\pm$0.00	0.18$\pm$0.06	200.00$\pm$0.00




图4。物理场的推理结果：蓝色方程为真实值；橙色方程由 PixelsPhys 推断得出。

详见附录?? 最后，*滑翔机* 案例凸显了Pixel2Phys的实用性：尽管由于复杂的三角函数项未能实现精确的符号匹配，但近乎完美的外推结果（ $R^2 = 0.9995$ ）以及图3 e中的视觉重叠均证实Pixel2Phys成功捕捉到了底层物理吸引子。此外，Pixel2Phys超越了模拟场景的限制，即使在复杂背景和噪声跟踪条件下，也能从真实世界视频中成功还原引力定律（详见附录??）。

5.2. 像素级动态机制的发现

在这些场景中，视频代表由偏微分方程（PDE）驱动的时间变化场的离散网格采样[8, 34]。其目的在于捕捉这些像素级相互作用，从而推导出底层的偏微分方程。

5.2.1. 数据集

我们针对四个具有代表性的反应扩散方程进行了实验：Lambda-Omega（LO）[8]、布鲁塞尔振荡器（Bruss）[29]、FitzHugh-Nagumo（FHN）[42] 和 Swift-Hohenberg（SH）[37]。我们以数据集的形式对这些微分方程进行了数值求解。数据生成的具体细节详见附录??。

5.2.2. 设置

基线方法可分为黑盒神经运算符和符号回归方法两类。这些模型能根据初始帧预测超过1,000步的演化过程（SH系统为200步）。我们采用均方根误差（RMSE）和有效预测步数（VPS）来评估性能，其中有效预测步数定义为预测误差始终低于特定阈值的时间段（具体细节见附录??）。

5.2.3. 主要结果

表2显示，黑盒神经算子在长期部署过程中会出现严重的误差累积，导致有效预测步数极低，这证实了隐式近似方法无法维持动态稳定性。无需物理约束限制。现有的符号学基准方法同样表现出显著的脆弱性：SGA-PDE和LLM-PDE常无法收敛，或得到标记为NaN的次优拟合结果。由于遗传算法的搜索空间缺乏约束，SGA 容易出现过拟合现象；而LLM-PDE则缺乏视觉感知能力，倾向于生成过于简化的表达式，从而遗漏精确项（详见附录?? 中的完整方程列表）。相比之下，Pixel2Phys通过在推理循环中整合精确的数值工具，在所有数据集上均实现了最低的 RMSE 值和近乎完美的稳定性。图4进一步证明，我们的框架能够准确识别复杂的高阶物理现象。

该方法通过引入双谐波项来精确捕捉其主导作用机制。此外，我们的框架可扩展应用于复杂的实际PIV数据集，能够准确恢复二维纳维-斯托克斯方程分量（详见附录??）。

5.3. 表征层面动态机制的发现

该类别涉及现实世界的科学记录数据，由于光照条件不受控以及传感器噪声的存在，这些数据的信噪比较低。因此，有效的物理组件是隐式嵌入其中的。研究目标是构建一个紧凑的表示空间，能够过滤视觉噪声，从而捕捉这些隐性的演化机制。

5.3.1. 数据集

我们收集了六段视频：其中四段展示了K的可视化效果。áRMá包括一条涡街（流体动力学）[31, 38]以及两个记录的Belousov-Zhabotinsky反应（化学振荡器）[18]。这两者均属于典型的复杂系统，虽受低维吸引子支配，但通过高维且带有噪声的视觉模式呈现。所有视频均经过裁剪并转换为灰度图像（详见附录??）。

5.3.2. 设置

我们以 FNO 、 Latent-ODE以及先进的视频生成模型 Wan2.2[43]作为基准进行对比评估。由于序列长度有限（少于300帧），模型均在完整序列上进行训练，并通过其从首帧自回归重建完整视频的能力进行评估。对于Wan2.2，我们冻结了预训练权重，并使用GPT-4o生成描述性文本提示作为条件输入。除 RMSE 外，我们还采用涡度误差[21]来评估涡度精度，其计算公式详见附录??。

5.3.3. 主要结果

图6展示了一个极具说服力的对比：采用14B参数的Wan2.2模型生成了视觉上逼真的纹理，但未能保持动态一致性——这体现在1.5秒和2.0秒时涡旋相对于真实值的空间偏移上。这源于生成式提示的定性特性（详见附录??），而Pixel2Phys则提炼了定量的控制规律（例如如图1c中的特征值 $\lambda_{2,3} \approx \pm 2.136i$ ），这些规律决定了严格的振荡周期（ $T \approx 0.294$ ）以确保精确对齐。从视觉上看，我们的预测纹理效果较差，这归因于协同优化机制的选择性过滤——不相关的成分（如不均匀光照）被剔除，从而提取出内在流形上的纯粹动力学特征。图5的定量结果进一步证实了这种物理保真度：Pixel2Phys始终取得最低的预测误差，表明所发现的简约规律成功捕捉了主导的高维行为，尽管去除了视觉噪声。




图5. 所有模型在物理现象视频上的预测误差比较。




图6. PixelsPhys与Wan2.2对水流视频的预测结果。

5.4. 消融研究与稳健性

为验证协同优化的必要性，我们将计划代理替换为静态串行工作流。如附录??所述，由于缺乏方程反馈循环，变量空间变得高度复杂，无法提炼出简洁有效的规律。我们进一步通过用小规模模型替代LLM主干网络来测试系统的鲁棒性。附录??的结果表明，即使推理能力有限，Pixel2Phys仍能保持优异的准确性，这证明我们的协作式代理架构有效降低了对原始模型规模的依赖。最后，附录??提供了针对各视频类别的详细案例研究，直观展示了逐级推理过程。

6. 结论

在本研究中，我们推出了Pixel2Phys框架——该框架能够自动从视觉动态数据中发现支配性规律。通过协调多个专用智能体，我们的方法用迭代协同优化流程取代了传统的静态处理流程。关键在于，该框架利用初步建立的符号化规律反向指导视觉变量的提取过程，有效解决了变量提取与规律发现之间的耦合问题。实验表明，Pixel2Phys不仅能推导出简洁的数学方程，还实现了稳健的长期外推能力，这标志着我们在构建可解释的视觉模型方面迈出了重要一步。

参考文献

- [1] 迪米特里奥斯·安吉利斯、菲利普斯·索福斯与西奥多罗斯·E·卡拉卡西迪斯。人工智能在物理科学中的应用：符号回归趋势与展望。《工程计算方法档案》，30(6):3845–3865,2023。1
- [2] 卢卡·比吉奥、托马索·本迪内利、亚历山大·尼茨、奥雷利安·卢基和詹巴蒂斯塔·帕拉斯坎多洛。可扩展的神经网络符号回归。收录于《国际机器学习会议》，第936–945页。PMLR, 2021。1
- [3] Abeba Birhane、Atoosa Kasirzadeh、David Leslie 和 Sandra Wachter。大型语言模型时代的科学。《自然·物理评论》，5(5):277–280,2023。1
- [4] Daniil A Boiko、Robert MacKnight、Ben Kline 和 Gabe Gomes。基于大型语言模型的自主化学研究。《Nature》，624(7992):570–578,2023。1
- [5] Oumayma Bounou、Jean Ponce 和 Justin Carpentier。基于感官输入的复杂动态系统的在线学习与控制。《神经信息处理系统进展》，34:27852–27864,2021。1, 2
- [6] Steven L Brunton、Joshua L Proctor 和 J Nathan Kutz。通过非线性动力系统的稀疏辨识从数据中发现控制方程。《美国国家科学院院刊》，113(15):3932–3937,2016。5
- [7] 曹青龙、王丁、李希瑞、陈云天、马超和杨晓康。基于潜在物理现象知识的教学视频扩散模型。《arXiv 预印本 arXiv:2411.11343》，2024。1, 4
- [8] 凯瑟琳·钱普曼、贝瑟尼·卢施、J·内森·库茨和史蒂文·L·布鲁顿。基于数据的坐标与控制方程发现。《美国国家科学院院刊》，116(45):22445–22451,2019。3、5、6、7
- [9] Boyuan Chen、Kuang Huang、Sunand Raghupathi、Ishaan Chandratreya、Qiang Du 和 Hod Lipson。实验数据中隐藏的基本变量的自动化发现。《Nature Computational Science》，2(7):433–442,2022。1
- [10] Ricky TQ Chen、Yulia Rubanova、Jesse Bettencourt 和 David K Duvenaud。神经常微分方程。《神经信息处理系统进展》，第31卷，2018年。2, 6
- [11] 陈云天、罗英涛、刘强、徐浩和张东晓。用于发现开放形式偏微分方程的符号遗传算法（sga-pde）。《物理评论研究》，4(2):023174,2022。7
- [12] 杜梦歌、陈云天、王忠正、聂龙峰和张东晓。用于非线性动力学自动方程发现的大语言模型。《流体物理学》，36(9)，2024。7
- [13] Stathi Fotiadis、Mario Lino Valencia、Shunlong Hu、Stef Garasto、Chris D. Cantwell 和 Anil Anthony Bharath。用于系统动力学稳健预测的解耦生成模型。《国际机器学习会议》，第10222–10248页。PMLR，2023。2
- [14] 约翰·古肯海默。van der Pol方程的动力学。《IEEE 电路与系统汇刊》，27(11): 983–989,1980。6
- [15] 文森特·勒古恩与尼古拉斯·托姆：从无监督视频数据中分离物理动力学与未知因素预测。收录于《IEEE/CVF 计算机视觉与模式识别会议论文集》，第11474–11484页，2020年。1, 2
- [16] Irina Higgins、Peter Wirsberger、Andrew Jaegle 和 Aleksandar Botev。《对称性：基于视觉推断的学习哈密顿动力学质量评估》。《神经信息处理系统进展》，34:25591–25605,2021年。
- [17] 弗洛里安·霍夫赫尔、卢卡斯·科斯特勒、弗洛里安·伯纳德和丹尼尔·克雷默斯。基于单个视频进行物理参数推断的神经隐式表征。收录于《IEEE/CVF 计算机视觉应用冬季会议论文集》，第2093–2103页，2023年。1, 2
- [18] JL Hudson 与 JC Mankin。贝洛索夫-扎博廷斯基反应中的混沌现象。《化学物理杂志》，74(11):6171–6177,1981。8
- [19] Yayati Jadhav 和 Amir Barati Farimani。基于视频的深度学习实现多粒子系统的主导运动识别。《神经计算与应用》，34(20): 18183–18193,2022。6
- [20] 米格尔·雅克、迈克尔·伯克与蒂莫西·霍斯佩达莱斯。物理作为逆图形：基于视频的无监督物理参数估计。《arXiv 预印本 arXiv:1905.11169》，2019。2
- [21] 郑镇熙与法兹勒·侯赛因。关于涡旋的识别。《流体力学杂志》，285:69–94,1995。8
- [22] Rama Krishna Kandukuri、Jan Achterhold、Michael Moeller 和 Joerg Stueckler。基于可微分物理的视频物理表征学习与参数识别。《国际计算机视觉杂志》，130(1): 3–16,2022。2
- [23] Alexander Kirillov、Eric Mintun、Nikhila Ravi、Hanzi Mao、Chloe Rolland、Laura Gustafson、Tete Xiao、Spencer Whitehead、Alexander C Berg、Wan-Yen Lo, et al. 任意分割。收录于《IEEE/CVF 国际计算机视觉会议论文集》，第4015–4026页,2023。4
- [24] William La Cava、Bogdan Burlacu、Marco Virgolin、Michael Kommenda、Patryk Orzechowski、Fabrizio Olivetti de France、Ying Jin 和 Jason H Moore。当代符号回归方法及其相对性能。《神经信息处理系统进展》，2021（DB1）：1,2021。1
- [25] 李瑞坤、王焕东与李勇。通过时间尺度自动分离学习慢速与快速系统动力学。收录于《第29届ACM SIGKDD 知识发现与数据挖掘会议论文集》，第4380–4390页，2023年。1
- [26] 李瑞坤、陆燕、唐世祥、齐碧清与欧阳万利。基于MLLM从高维数据中发现内在坐标与控制方程。《arXiv 预印本 arXiv:2505.11940》，2025。1
- [27] 李宗义、尼古拉·科瓦奇基、卡米亚尔·阿齐扎德内谢利、刘伯吉德、考希克·巴塔查里亚、安德鲁·斯图尔特与阿尼玛·阿南德库马尔。参数型偏微分方程的傅里叶神经算子。《arXiv 预印本 arXiv:2010.08895》，2020。7

- [28] Yixin Liu, Kai Zhang, Yuan Li, Zhiling Yan, Chujie Gao, Ruoxi Chen, Zhengqing Yuan, Yue Huang, Hanchi Sun, Jianfeng Gao, 等. Sora: 大型视觉模型的背景, 技术, 局限性与机遇综述. *arXiv 预印本 arXiv:2402.17177*, 2024. [1](#)
- [29] Ryan Lopez 和 Paul J Atzberger. Gd-vaes: 用于学习非线性动力学和降维的几何动态变分自编码器. *arXiv 预印本 arXiv:2206.05183*, 2022. [7](#)
- [30] Lele Luan, Yang Liu 与 Hao Sun. 从视频中提炼动态系统的控制律与源输入. *arXiv 预印本 arXiv:2205.01314*, 2022. [3](#), [6](#)
- [31] Bernd R Noack, Konstantin Afanasiev, Marek Morzyński, Gilead Tadmor 和 Frank Thiele. 瞬态及后瞬态圆柱尾流的低维模型层级体系. *流体力学杂志*, 497:335–363, 2003. [8](#)
- [32] Phillip Pope, Chen Zhu, Ahmed Abdelkader, Micah Goldblum 和 Tom Goldstein. 图像的内在维度及其对学习的影响. *arXiv 预印本 arXiv:2104.08894*, 2021. [1](#)
- [33] 阿什库尔·拉赫曼博士、扎卡里·E·罗斯与卡米亚尔·阿齐扎德内谢利. U 形神经算子. *arXiv 预印本 arXiv:2204.11127*, 2022. [7](#)
- [34] Samuel H Rudy, Steven L Brunton, Joshua L Proctor 和 J Nathan Kutz. 偏微分方程的数据驱动发现. *Science Advances*, 3(4):e1602614, 2017. [7](#)
- [35] 帕尔辛·肖贾伊、卡泽姆·梅达尼、阿米尔·巴拉蒂·法里马尼和钱丹·雷迪. 基于变换器的符号回归规划. *神经信息处理系统进展*, 36:45907–45919, 2023. [1](#)
- [36] R. Charles Swanson 和 Eli Turkel. 关于中心差分法与迎风格式. *计算物理学杂志*, 101(2):292–306, 1992. [5](#)
- [37] 杰克·斯威夫特与皮埃尔·C·霍亨伯格. 对流不稳定性处的流体动力学涨落. *《物理评论A》*, 15(1): 319, 1977. [7](#)
- [38] 平井邦彦、Steven L Brunton、Scott TM Dawson、Clarence W Rowley、Tim Colonius、Beverley J McKeon、Oliver T Schmidt、Stanislav Gordeyev、Vassilios Theofilis 与 Lawrence S Ukeiley. 流体流动的模式分析: 概述. *AIAA 期刊*, 55(12): 4013–4041, 2017. [8](#)
- [39] Wassim Tenachi, Rodrigo Ibata 和 Foivos I Diakogiannis. 基于单位约束的物理深度符号回归: 迈向物理定律的自动化发现. *《天体物理学杂志》*, 959(2):99, 2023. [1](#)
- [40] Tapas Tripura 和 Souvik Chakraborty. 用于求解计算力学问题中参数型偏微分方程的小波神经算子. *《应用力学与工程中的计算机方法》*, 404:115783, 2023. [7](#)
- [41] Silviu-Marian Udrescu 与 Max Tegmark. 符号性进展: 从扭曲视频中发现物理定律. *Physical Review E*, 103(4): 043307, 2021. [3](#), [6](#)
- [42] 潘泰利斯·R·弗拉哈斯、乔治奥斯·阿拉姆帕齐斯、卡罗琳·乌勒和彼得罗斯·库穆察科斯. 通过学习复杂系统的有效动力学进行多尺度模拟. *《自然·机器学习》*, 4(4):359–366, 2022. [7](#)
- [43] Team Wan, Ang Wang, Baole Ai, Bin Wen, Chaojie Mao, Chen-Wei Xie, Di Chen, Feiwu Yu, Haiming Zhao, Jianxiao Yang, 等. Wan: 开放且先进的大规模视频生成模型. *arXiv 预印本 arXiv:2503.20314*, 2025. [8](#)
- [44] 王一群、Nicholas Wagner 和 James M Rondinelli. 材料科学中的符号回归. *MRS Communications*, 9(3):793–805, 2019. [1](#)
- [45] 郝武、范旭、陈冲、华先胜、罗晓和王海新. Pastnet: 为时空视频预测引入物理感应偏置. 收录于 *第32届 ACM 国际多媒体会议论文集*, 第2917–2926页, 2024. [4](#)
- [46] 吴新恒、卢杰、严正和张光泉. 无监督视频预测中随机偏微分方程动力学的解耦. *IEEE 神经网络与学习系统汇刊*, 2023. [1](#), [2](#)
- [47] 杨宗延、贾斯蒂尼安·罗斯卡、卡蒂克·纳拉辛汉和彼得·J·拉姆奇. 利用自编码器学习物理约束动力学. *《神经信息处理系统进展》*, 35:17157–17172, 2022. [2](#)
- [48] 杰英、林浩伟、赵跃、陈亚杰、肖超、史全奇、梁一涛、周新桐、周元和马建柱. 空间物理学的神经符号模型. *《自然·机器学习》*, 第1–16页, 2025年. [1](#)
- [49] 张子桐、刘阳和孙浩. 基于视觉的三维移动目标非线性动力学发现. *arXiv 预印本 arXiv:2404.17865*, 2024. [3](#)